Certamen Formativo (Pauta Incluida) Fecha: 27/10/2026
Seminario de Telemática I Prof. Mauricio Araya
AGENTES INTELIGENTES Y PROBABILIDAD Puntaje Ideal: 100 pts

1. Preguntas de Desarrollo (30 p)

i) ¿Cómo cambia el modelado de un agente cuando pasa de operar en un ambiente totalmente observable (clásico MDP) a uno parcialmente observable (POMDP)? Explique específicamente el rol y la estructura matemática del concepto de "Creencia" (Belief). *(10 pts)*

SOLUCIÓN ESPERADA:

En un MDP clásico, el agente conoce con certeza el estado actual s, por lo que la política mapea $S \rightarrow A$. En un ambiente parcialmente observable (POMDP), el agente sufre de *incertidumbre epistémica*: no conoce el estado, solo recibe una observación o generada por una función de emisión $Z(o|s)$.

Para lidiar con esto, el agente mantiene una **Creencia (Belief - b)**, que es una distribución de probabilidad sobre todo el espacio de estados posibles (ej. 30% en estado A, 70% en estado B). El modelado cambia drásticamente porque el problema original se transforma en un MDP continuo sobre el espacio de creencias (Δ), donde la ecuación de Bellman evalúa la recompensa esperada dada esa distribución de probabilidad, y las transiciones actualizan la creencia en lugar del estado físico.

ii) En el contexto del modelado probabilista, explique la diferencia fundamental entre la *incertidumbre aleatoria* (aleatoric) y la *incertidumbre epistémica*. ¿Cuál de ellas puede ser teóricamente reducida por el agente al recolectar más observaciones del entorno? Justifique. *(10 pts)*

SOLUCIÓN ESPERADA:

La **incertidumbre aleatoria** se refiere al ruido físico o la estocasticidad inherente del sistema (por ejemplo, tirar un dado o la interferencia térmica en un sensor). Esta incertidumbre es *irreducible*; no importa cuántos datos recopile el agente, el evento futuro seguirá siendo probabilístico (modelado típicamente con ruido Gaussiano mediante el Teorema del Límite Central).

La **incertidumbre epistémica** surge de la ignorancia o falta de conocimiento del agente sobre variables ocultas o sobre los parámetros del modelo (Ej. no saber si una moneda está cargada). **Esta es la que puede ser reducida**. A medida que el agente recolecta más observaciones y aplica Inferencia Bayesiana (actualizando su *Posterior* a partir de su *Prior* y el *Likelihood*), la distribución de probabilidad se vuelve más estrecha, disminuyendo su ignorancia sobre la verdadera naturaleza del sistema.

iii) Al realizar inferencia exacta en una Red Bayesiana (por ejemplo, para diagnosticar una falla), ¿por qué es matemáticamente necesario aplicar el proceso de "marginalización" cuando existen variables intermedias no observadas entre la causa raíz y la evidencia observada? *(10 pts)*

SOLUCIÓN ESPERADA:

La marginalización es necesaria porque para aplicar el Teorema de Bayes necesitamos evaluar la probabilidad conjunta de la evidencia dada la hipótesis ($P(Evidencia \mid Hipótesis)$). Sin embargo, si la influencia de la hipótesis sobre la evidencia fluye a través de una variable intermedia (nodo) cuyo estado es desconocido, no existe una probabilidad directa en la Tabla de Probabilidades Condicionales (CPT) que relacione ambas de forma aislada.

La marginalización (o Regla de la Suma) resuelve esto iterando sobre todos los estados mutuamente excluyentes de la variable oculta intermedia. Suma el peso probabilístico de cada "ruta" posible (Ej: $P(E|H) = P(E|Int=1)P(Int=1|H) + P(E|Int=0)P(Int=0|H)$), permitiendo conectar matemáticamente la causa y

2. Preguntas de Selección Múltiple (20 p)

Seleccione la alternativa correcta (5 pts cada una).

i) En una Cadena de Markov, la propiedad fundamental de Markov establece que:

a. a) El estado futuro depende de forma determinista de toda la historia previa.
b. b) El estado futuro es independiente del pasado, dado el estado presente.
c. c) Las probabilidades de transición son siempre estáticas e iguales para todo estado.
d. d) Es imposible alcanzar un equilibrio estadístico a largo plazo.

> **SOLUCIÓN: b**
>
> La propiedad de Markov dicta que $Pr(S_{t+1} \mid S_t, S_{t-1}, \ldots, S_0) = Pr(S_{t+1} \mid S_t)$. La historia previa no aporta información adicional si ya conocemos el presente.

ii) En los Modelos de Markov Ocultos (HMM), ¿qué algoritmo se utiliza específicamente para realizar la tarea de "Filtrado" (estimar el estado de creencia actual $P(s_t|o_{1:t})$)?

a. a) Algoritmo de Viterbi.
b. b) Búsqueda A* con heurística de probabilidad.
c. c) Algoritmo de Baum-Welch.
d. d) Algoritmo Forward (Programación Dinámica).

> **SOLUCIÓN: d**
>
> El Algoritmo Forward acumula la probabilidad conjunta paso a paso combinando la matriz de Transición (T) y la de Observación (Z). Viterbi es para la secuencia más probable, y Baum-Welch para aprendizaje.

iii) El Teorema del Límite Central es frecuentemente utilizado en el razonamiento probabilista para justificar que:

a. a) La incertidumbre epistémica siempre se reduce a cero a largo plazo.
b. b) El ruido no modelado producto de la suma de múltiples variables independientes se distribuye como una Campana de Gauss (Normal).
c. c) Las redes bayesianas no pueden contener ciclos cerrados.
d. d) La función de recompensa en un POMDP debe ser estrictamente positiva.

> **SOLUCIÓN: b**
>
> El TLC establece que la suma de muchas variables aleatorias independientes tiende a una distribución Normal, justificando el uso de ruido Gaussiano ($\varepsilon \sim N(\mu, \sigma^2)$) en el modelado de variables continuas no medidas.

3. Verdadero o Falso (15 p)

Indique si la afirmación es Verdadera (V) o Falsa (F) y justifique brevemente (3 pts cada una).

i) En el equilibrio estadístico de una Cadena de Markov, la aplicación iterativa de la matriz de transición sigue alterando drásticamente la distribución de probabilidad de los estados. ____

> **SOLUCIÓN: Falso**
>
> En el equilibrio, la distribución de probabilidad se estabiliza y permanece inalterada tras aplicar la matriz de

iii) El aprendizaje Libre de Modelo (Model-Free, como Q-Learning) se caracteriza por construir empíricamente y almacenar en memoria las matrices de transición T y recompensa R del entorno para luego aplicar Ecuaciones de Bellman. ____

> **SOLUCIÓN: Falso**
>
> Eso describe el aprendizaje Basado en Modelo (Model-Based). El enfoque Libre de Modelo (Model-Free) evita intentar estimar T o R, aprendiendo en su lugar el valor empírico directo de las acciones (valores Q) a través del error de diferencia temporal.

IV. Problemas Aplicados (35p)

Problema 1: Filtrado en HMM (15 pts)

Considere un modelo de Markov Oculto que rastrea el estado operativo de una máquina de red. La máquina puede estar en dos estados: $S = \{Ok, Falla\}$. Las transiciones diarias están dadas por la matriz T (columnas = estado en $t-1$, filas = estado en t). El sistema emite alertas de diagnóstico observables $O = \{Verde, Rojo\}$ dadas por la matriz de emisión Z (columnas = estado real, filas = alerta observada).

$$T = \begin{vmatrix} 0.8 & 0.3 \\ 0.2 & 0.7 \end{vmatrix}$$

(Filas: Ok, Falla)

$$Z = \begin{vmatrix} 0.6 & 0.1 \\ 0.4 & 0.9 \end{vmatrix}$$

(Filas: Verde, Rojo)

Asuma que en el día 0, el técnico no tiene información y asigna una creencia inicial uniforme: $\alpha_0 = [0.5, 0.5]$. En el día 1, el sistema emite una alerta **Verde**. Utilizando el algoritmo Forward, calcule la creencia exacta (probabilidad de estar Ok vs Falla) tras esta observación.

> **SOLUCIÓN ESPERADA:**
>
> La ecuación del algoritmo Forward en notación vectorial es: $\alpha_1 = diag(Z_{Verde}) \times T \times \alpha_0$.
>
> **Paso 1: Predicción (Multiplicar T por α_0)**
>
> $$\begin{vmatrix} 0.8 & 0.3 \\ 0.2 & 0.7 \end{vmatrix} \times \begin{vmatrix} 0.5 \\ 0.5 \end{vmatrix} = \begin{vmatrix} (0.8\times0.5) + (0.3\times0.5) \\ (0.2\times0.5) + (0.7\times0.5) \end{vmatrix} = \begin{vmatrix} 0.55 \\ 0.45 \end{vmatrix}$$
>
> **Paso 2: Actualización (Extraer fila "Verde" de Z, crear matriz diagonal y multiplicar)**
> La fila "Verde" de Z es $[0.6, 0.1]$. La convertimos en matriz diagonal:
>
> $$\begin{vmatrix} 0.6 & 0 \\ 0 & 0.1 \end{vmatrix} \times \begin{vmatrix} 0.55 \\ 0.45 \end{vmatrix} = \begin{vmatrix} 0.6 \times 0.55 \\ 0.1 \times 0.45 \end{vmatrix} = \begin{vmatrix} 0.330 \\ 0.045 \end{vmatrix}$$
>
> **Paso 3: Normalización**
> Calculamos la evidencia (suma de los términos): $P(O=Verde) = 0.330 + 0.045 = 0.375$.
> Dividimos el vector actualizado por esta suma para obtener las probabilidades finales:
> - Probabilidad de estado Ok: $0.330 / 0.375 = 0.88$ (88%)
> - Probabilidad de estado Falla: $0.045 / 0.375 = 0.12$ (12%)

Problema 2: Inferencia en Redes Bayesianas (20 pts)

Se ha modelado una pequeña granja eólica. El evento Lluvia (***Ll***) afecta si los Sensores de Humedad reportan Falla (***F***). A su vez, una Falla en los sensores puede activar una Parada de Emergencia (***P***). La estructura causal es lineal: ***Ll*** → ***F*** → ***P***. Las probabilidades son (1 = Verdadero, 0 = Falso):

- Probabilidad inicial: ***P(Ll=1) = 0.2***
- CPT Sensores: ***P(F=1 | Ll=1) = 0.9***, ***P(F=1 | Ll=0) = 0.1***
- CPT Parada: ***P(P=1 | F=1) = 0.8***, ***P(P=1 | F=0) = 0.05***

i) Calcule la probabilidad marginal (total) de que los sensores reporten Falla, es decir, ***P(F=1)***. (10 pts)

ii) Asuma que un operador ve por la ventana y confirma que está lloviendo (***Ll=1***). Utilizando las reglas de independencia condicional de las Redes Bayesianas, calcule la probabilidad predecida de que ocurra una Parada de Emergencia, es decir, ***P(P=1 | Ll=1)***. (10 pts)

SOLUCIÓN ESPERADA:

i) Cálculo de P(F=1):
No tenemos evidencia, por lo que aplicamos el teorema de la probabilidad total (marginalización) sobre su nodo padre (Lluvia).

P(F=1) = P(F=1 | Ll=1)P(Ll=1) + P(F=1 | Ll=0)P(Ll=0)
Sabemos que ***P(Ll=0) = 1 - 0.2 = 0.8***.
P(F=1) = (0.9 × 0.2) + (0.1 × 0.8)
P(F=1) = 0.18 + 0.08 = 0.26 (26%)

ii) Cálculo de P(P=1 | Ll=1):
Para conectar la Lluvia con la Parada, la información debe fluir a través del nodo intermedio Falla (***F***), el cual no hemos observado. Debemos marginalizar sobre ***F***. Como ***P*** depende condicionalmente solo de ***F***, podemos plantear:

P(P=1 | Ll=1) = P(P=1 | F=1)P(F=1 | Ll=1) + P(P=1 | F=0)P(F=0 | Ll=1)

Extraemos las probabilidades de las CPTs:
- ***P(P=1 | F=1) = 0.8***
- ***P(F=1 | Ll=1) = 0.9***
- ***P(P=1 | F=0) = 0.05***
- ***P(F=0 | Ll=1) = 1 - P(F=1|Ll=1) = 1 - 0.9 = 0.1***

Reemplazando en la ecuación:
P(P=1 | Ll=1) = (0.8 × 0.9) + (0.05 × 0.1)
P(P=1 | Ll=1) = 0.72 + 0.005 = 0.725 (72.5%)