Modelos de Markov Ocultos (HMM)

Mauricio Araya
mauricio.araya@usm.cl

November 4, 2020

Contents

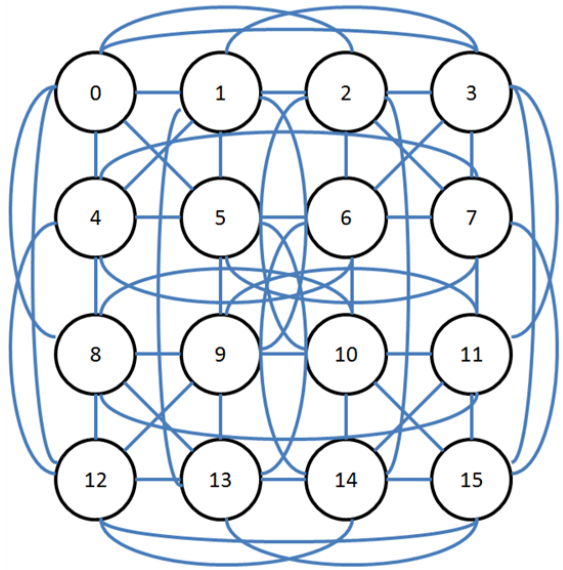
1. Cadenas de Markov
   - El Modelo
   - Métodos
   - Aplicaciones
2. Modelos de Markov Ocultos
   - El Modelo
   - Métodos

Contents

1. Cadenas de Markov
   - El Modelo
   - Métodos
   - Aplicaciones
2. Modelos de Markov Ocultos
   - El Modelo
   - Métodos

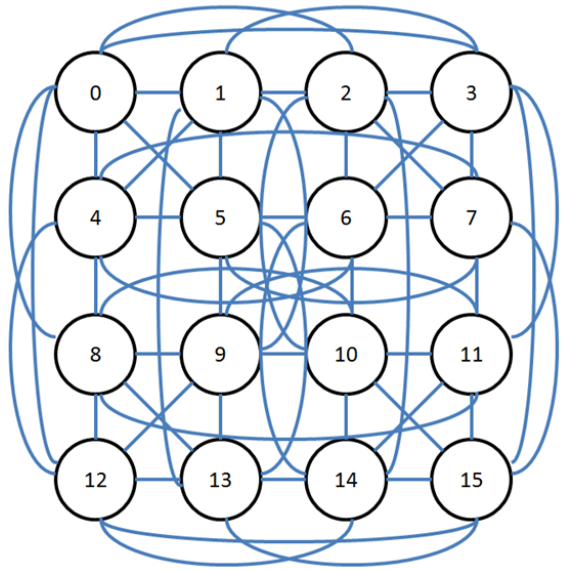
Modelos de Markov

- **Modelo**: un conjunto de variables interconectadas

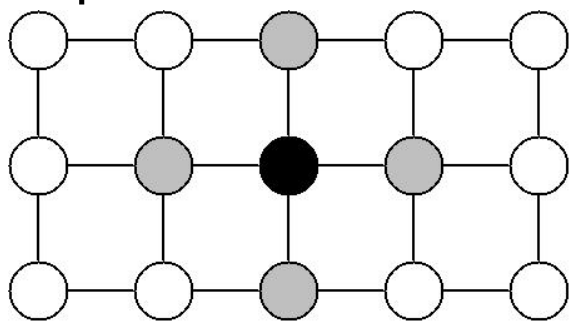


Modelos de Markov

- **Modelo**: un conjunto de variables interconectadas

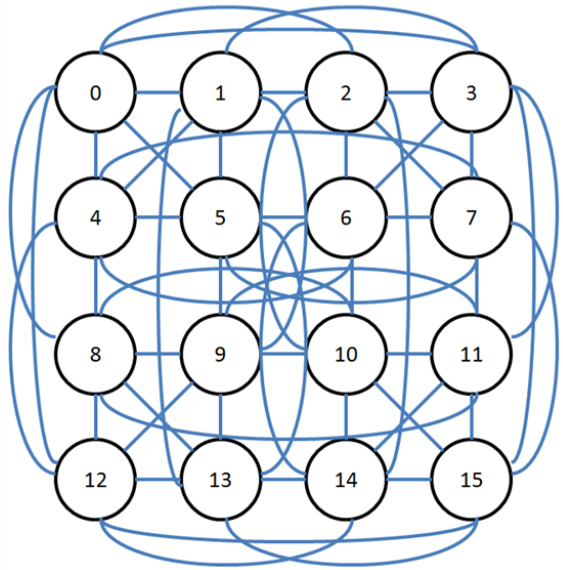


- **Markov**: "Las variables dependen sólo de sus vecinos directos"

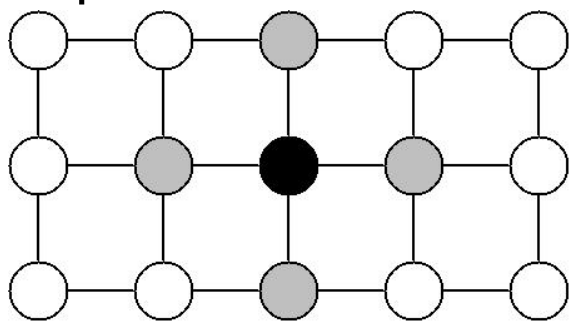


Modelos de Markov

- **Modelo**: un conjunto de variables interconectadas



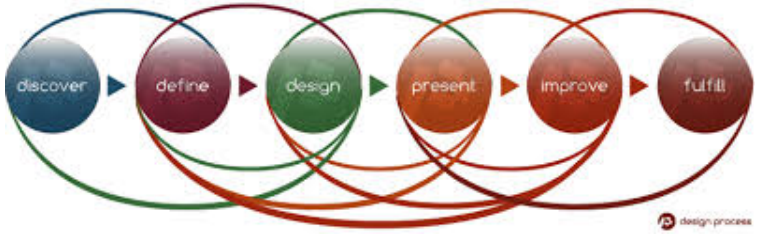
- **Markov**: "Las variables dependen sólo de sus vecinos directos"



- **Ventaja**: Restricción al modelado para simplificar el problema
- **Desventaja**: Modelar con la restricción de Markov

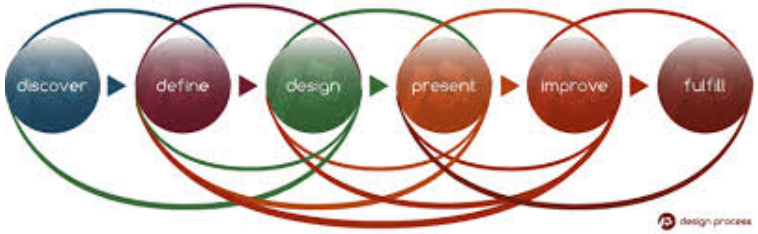
Procesos Estocásticos

- **Proceso**: variables que cambian en el tiempo
- **Estado**: valor de las variables en un tiempo determinado

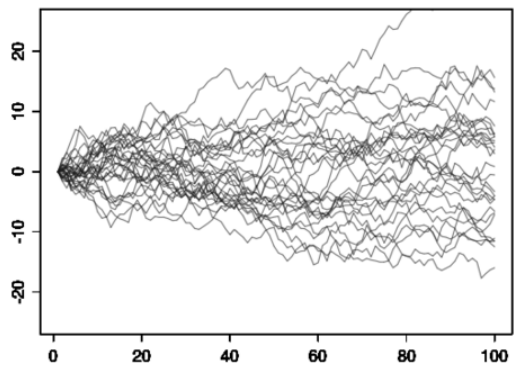


Procesos Estocásticos

- **Proceso**: variables que cambian en el tiempo
- **Estado**: valor de las variables en un tiempo determinado

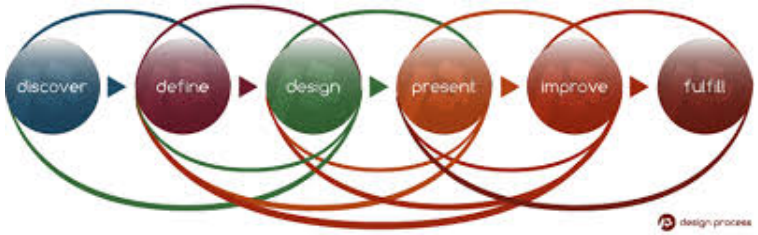


- **Estocástico**: la transición de estados depende de probabilidades
- **Formalmente**: el estado es una variable aleatoria en el tiempo

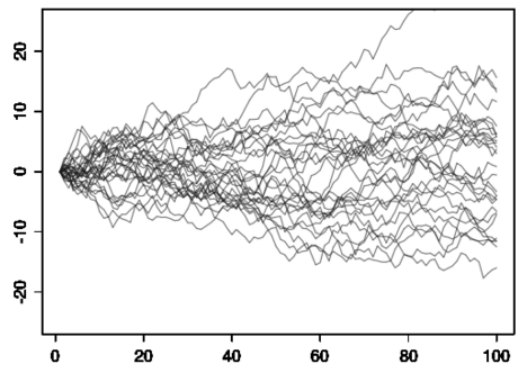


Procesos Estocásticos

- **Proceso**: variables que cambian en el tiempo
- **Estado**: valor de las variables en un tiempo determinado



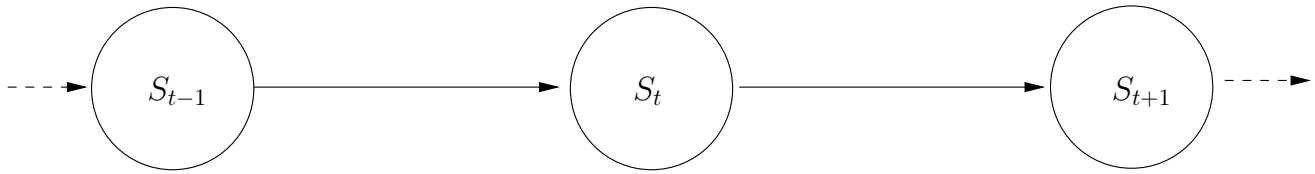
- **Estocástico**: la transición de estados depende de probabilidades
- **Formalmente**: el estado es una variable aleatoria en el tiempo



- **Desventaja**: difícil manejar tantas variables
- **Ejemplo**: el estudiante desconcentrado

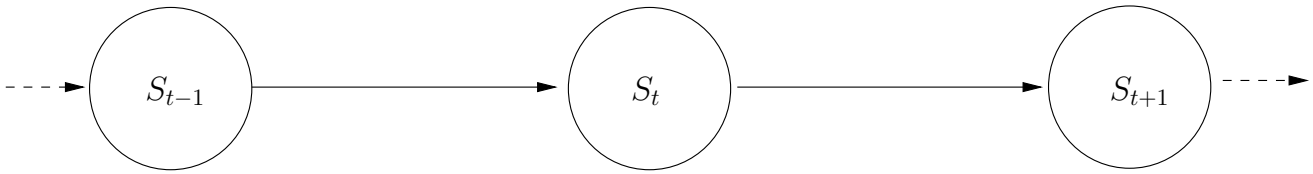
Procesos Markovianos (Cadenas de Markov)

- **Markov**: "El futuro es independiente del pasado, dado el presente"
- **Es decir**: Mi estado actual depende sólo de mi estado anterior



Procesos Markovianos (Cadenas de Markov)

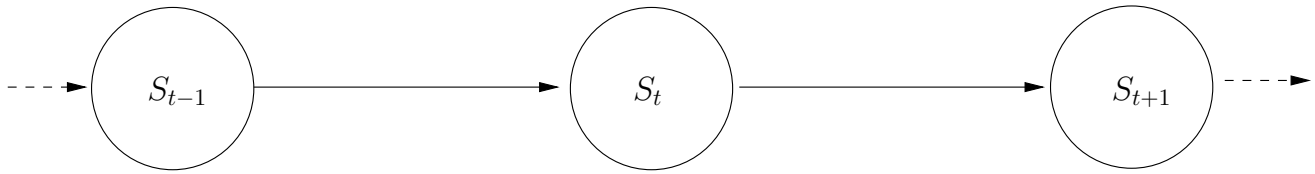
- **Markov**: "El futuro es independiente del pasado, dado el presente"
- **Es decir**: Mi estado actual depende sólo de mi estado anterior



- **Recuerde**: Sólo es una restricción de modelado
- **Ejemplo**: ¿Dónde está el tren?

Procesos Markovianos (Cadenas de Markov)

- **Markov**: "El futuro es independiente del pasado, dado el presente"
- **Es decir**: Mi estado actual depende sólo de mi estado anterior



- **Recuerde**: Sólo es una restricción de modelado
- **Ejemplo**: ¿Dónde está el tren?
- **Formalmente**: $Pr(X_{t+1}|X_t, X_{t-1}, \ldots, X_0) = Pr(X_{t+1}|X_t)$
- **Función de Transición**: e.g., matriz con los valores de $Pr(\cdot|\cdot)$

$X_{t+1}\|X_t$	S_1	S_2	$\ldots$	S_n
S_1	0.1	0.2		0.01
S_2	0.4	0.03		0.21
$\vdots$			$\ddots$	
S_n	0.22	0.23		0.1

Probabilidades en Cadenas de Markov

- **Ejemplo**: Estudiante Desconcentrado Markoviano
- **Matriz de transición**: $Pr(S'|S) =$

$S'\|S$	c	d
c	0.6	0.2
d	0.4	0.8
Σ	1.0	1.0

Probabilidades en Cadenas de Markov

- **Ejemplo**: Estudiante Desconcentrado Markoviano
- **Matriz de transición**: $Pr(S'|S) =$

$S'\|S$	c	d
c	0.6	0.2
d	0.4	0.8
Σ	1.0	1.0

Si $S_0 = c$...

- **a)** $Pr(S_1 = c|S_0 = c)$

Probabilidades en Cadenas de Markov

- **Ejemplo**: Estudiante Desconcentrado Markoviano
- **Matriz de transición**: $Pr(S'|S) =$

$S'\|S$	c	d
c	0.6	0.2
d	0.4	0.8
Σ	1.0	1.0

Si $S_0 = c$...

- **a)** $Pr(S_1 = c|S_0 = c) \longrightarrow 0.6$

Probabilidades en Cadenas de Markov

- **Ejemplo**: Estudiante Desconcentrado Markoviano
- **Matriz de transición**: $Pr(S'|S) =$

$S'\|S$	c	d
c	0.6	0.2
d	0.4	0.8
Σ	1.0	1.0

Si $S_0 = c$...

- **a)** $Pr(S_1 = c|S_0 = c) \longrightarrow 0.6$
- **b)** $Pr(S_2 = c|S_0 = c)$

Probabilidades en Cadenas de Markov

- **Ejemplo**: Estudiante Desconcentrado Markoviano
- **Matriz de transición**: $Pr(S'|S) =$

$S'\|S$	c	d
c	0.6	0.2
d	0.4	0.8
Σ	1.0	1.0

Si $S_0 = c$...

- **a)** $Pr(S_1 = c|S_0 = c) \longrightarrow 0.6$
- **b)** $Pr(S_2 = c|S_0 = c) \longrightarrow 0.44$

$$\sum_{x \in \{c,d\}} Pr(S_2 = c|S_1 = x)Pr(S_1 = x|S_0 = c) = 0.6 \times 0.6 + 0.2 \times 0.4$$

- **c)** $Pr(S_6 = c|S_0 = c)$

Probabilidades en Cadenas de Markov

- **Ejemplo**: Estudiante Desconcentrado Markoviano
- **Matriz de transición**: $Pr(S'|S) =$

$S'\|S$	c	d
c	0.6	0.2
d	0.4	0.8
Σ	1.0	1.0

Si $S_0 = c$...

- **a)** $Pr(S_1 = c|S_0 = c) \longrightarrow 0.6$
- **b)** $Pr(S_2 = c|S_0 = c) \longrightarrow 0.44$

$$\sum_{x \in \{c,d\}} Pr(S_2 = c|S_1 = x)Pr(S_1 = x|S_0 = c) = 0.6 \times 0.6 + 0.2 \times 0.4$$

- **c)** $Pr(S_6 = c|S_0 = c) \longrightarrow 0.33606$

Note que... $P_{ik} = \sum_j T_{ij}T_{jk} \longrightarrow T \times T$

Por lo que $T_6 = \prod_{i=1}^{6} T \longrightarrow$

$S_6\|S_0$	c	d
c	**0.33606**	0.33197
d	0.66394	0.66803

Equilibrio Estadístico en Cadenas de Markov

- **¿Qué pasa?**: $t \to \infty$

$S_\infty \vert S_0$	c	d
c	0.33333	0.33333
d	0.66667	0.66667

Equilibrio Estadístico en Cadenas de Markov

- **¿Qué pasa?**: $t \to \infty$

$S_\infty \mid S_0$	c	d
c	0.33333	0.33333
d	0.66667	0.66667

- **Equilibrio:** En algún punto $T \times T_t = T_t$
- **Resolución:**

$$\begin{bmatrix} 0.6 & 0.2 \\ 0.4 & 0.8 \end{bmatrix} \times \begin{bmatrix} p & p \\ 1-p & 1-p \end{bmatrix} = \begin{bmatrix} p & p \\ 1-p & 1-p \end{bmatrix}$$

$$\begin{aligned} 0.6p + 0.2 - 0.2p = p & \qquad = 1/3 \\ 0.4p + 0.8 - 0.8p = 1 - p & \qquad = 2/3 \end{aligned}$$

Ejercicio

Democratización

Un estudio reciente dice que un país en dictadura tiene 20% de probabilidades de convertirse en democracia cada año, y que las democracias sólo tienen un 5% de probabilidades de convertirse en dictadura.

- a) ¿Qué indica el sentido común?

Ejercicio

Democratización

Un estudio reciente dice que un país en dictadura tiene 20% de probabilidades de convertirse en democracia cada año, y que las democracias sólo tienen un 5% de probabilidades de convertirse en dictadura.

- a) ¿Qué indica el sentido común?
  Qué las dictaduras se deberían tender a 0 eventualmente... ¿?
- b) ¿Cuál es la probabilidad de que un país cualquiera esté en dictadura en el futuro?

Ejercicio

Democratización

Un estudio reciente dice que un país en dictadura tiene 20% de probabilidades de convertirse en democracia cada año, y que las democracias sólo tienen un 5% de probabilidades de convertirse en dictadura.

- a) ¿Qué indica el sentido común?
  Qué las dictaduras se deberían tender a 0 eventualmente... ¿?
- b) ¿Cuál es la probabilidad de que un país cualquiera esté en dictadura en el futuro?
  $0.95p + 0.2 - 0.2p = p \longrightarrow 1 - p = 1/5$

Aprendizaje en Cadenas de Markov

- **Problema Inverso**: observamos una secuencia de estados de los estudiantes
- **Ejemplo**: `lst = c c c c d d c d d d c d d d d d c c c c c c c c c`

Aprendizaje en Cadenas de Markov

- **Problema Inverso**: observamos una secuencia de estados de los estudiantes
- **Ejemplo**: `lst = c c c c d d c d d d c d d d d d c c c c c c c c c`
- **Problema**: ¿Cuál es la matriz de transición?
- **Opción Frecuentista**: cuento cuantos $c \to c$, $c \to d$, $d \to c$ y $d \to d$.

$S'\|S$	c	d
c	11	3
d	3	7
Σ	14	10

- **Opción Bayesiana**: $X_{|c}$ y $X_{|y}$ son v.a. que siguen una distribución (Beta) con parámetros iniciales θ_0

$$Pr(S|S', \theta) = Pr(S|S', lst, \theta_0) \propto Pr(lst|S, S', \theta_0) Pr(S|S', \theta_0)$$

¿Para qué sirven?

Cualquier aplicación con datos secuenciales!

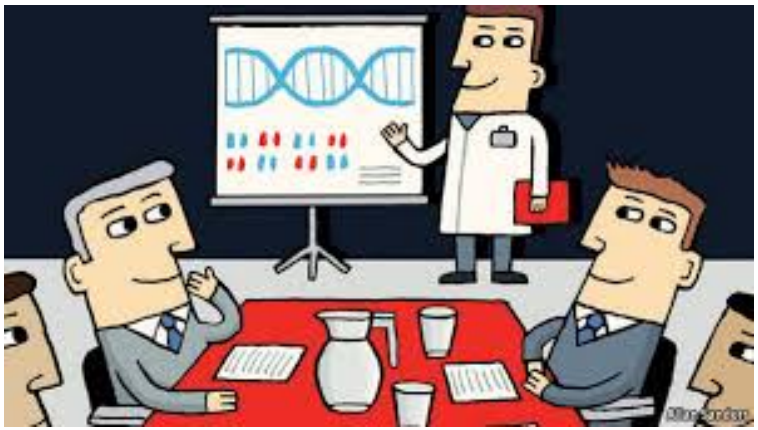
- **Procesamiento de Texto**: predecir texto (T9), reconocimiento sintáctico, etc
- **Robótica**: planificación de rutas, decisiones autónomas, etc



¿Para qué sirven?

Cualquier aplicación con datos secuenciales!

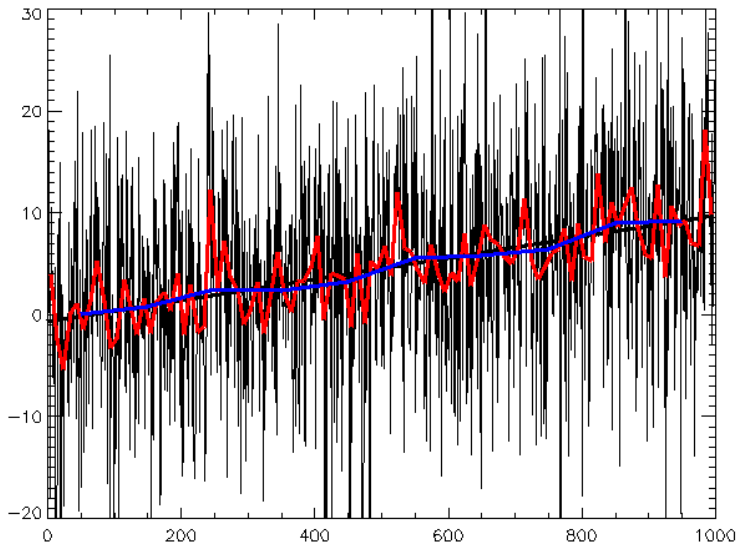
- **Economía**: predicción en mercados y bolsa, análisis de inversiones, etc
- **Biología**: comportamiento celular, secuencias de ADN, etc



¿Para qué sirven?

Cualquier aplicación con datos secuenciales!

- **Procesamiento de Señales**: predicción y análisis de señales complejas, reducción de ruido, etc
- **Biomédica**: e.g., análisis de señales cerebrales



Contents

1. Cadenas de Markov
   - El Modelo
   - Métodos
   - Aplicaciones

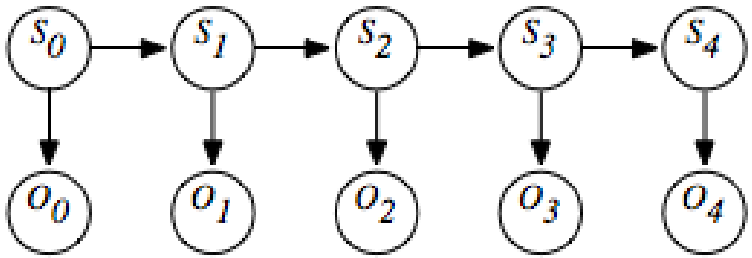
2. Modelos de Markov Ocultos
   - El Modelo
   - Métodos

Cadenas de Markov y Realidad

- **Conjunto de Estados**: normalmente muy grande o continuo
  - Inferencia más compleja y genérica
  - Distribuciones de probabilidad continuas (arbitrarias)
  - Maldición de la dimensionalidad
  - Funciones de transición enormes pero dispersas
  - **Solución:** Estadística, Machine Learning, Inteligencia Artificial, Optimización, etc...
- **Observabilidad**: no todo lo modelable es observable
  - Existe ruido o perturbaciones al observar una variable
  - Se sabe que existen variables ocultas
  - La restricción de Markov suele forzar este escenario (tren!)
  - **Solución**: Métodos Bayesianos/Gráficos $\longrightarrow$ HMM

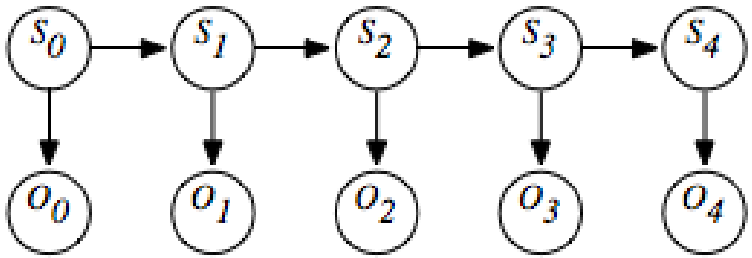
Cadenas de Markov Ocultas

Principio: en cada instante de tiempo obtengo una observación, no un estado

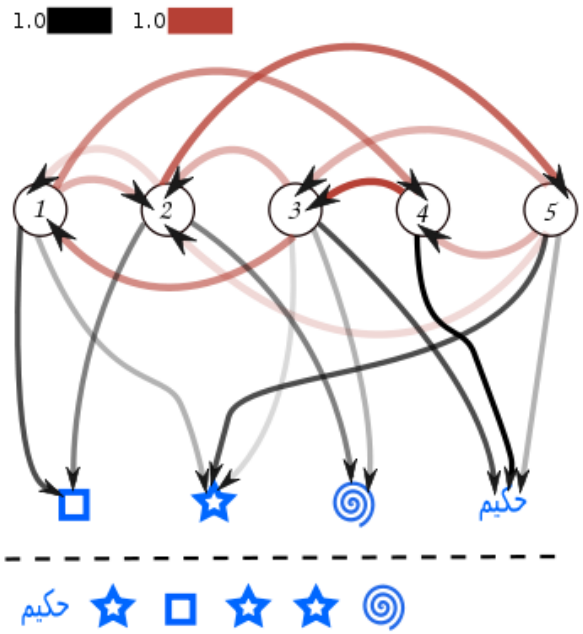


Cadenas de Markov Ocultas

Principio: en cada instante de tiempo obtengo una observación, no un estado

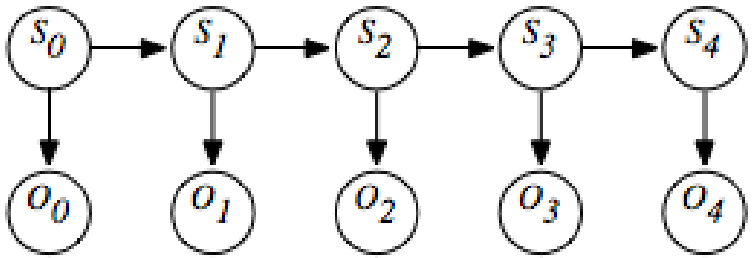


Es decir: estado del sistema no disponible, solo información parcial

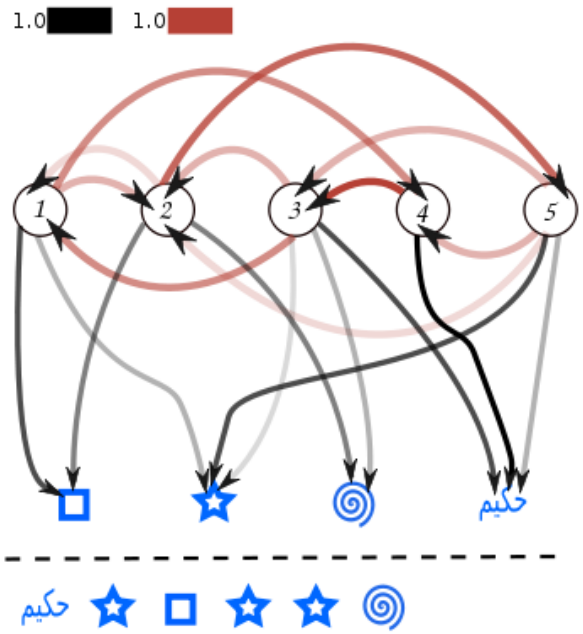


Cadenas de Markov Ocultas

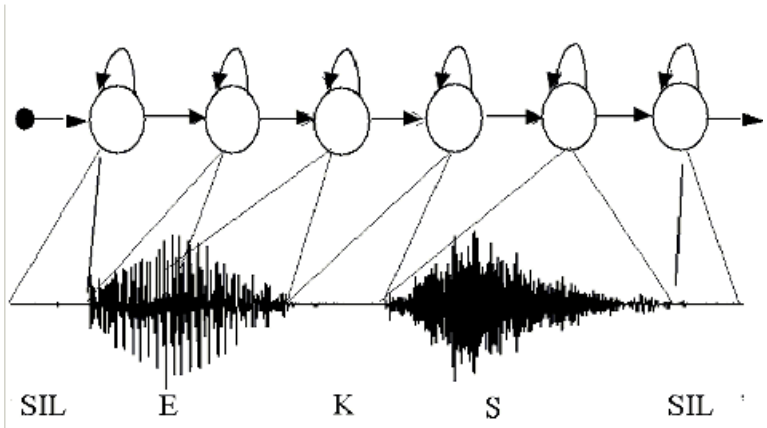
Principio: en cada instante de tiempo obtengo una observación, no un estado



Es decir: estado del sistema no disponible, solo información parcial



Función de Observación: como se generan las observaciones a partir de un estado



Formalmente

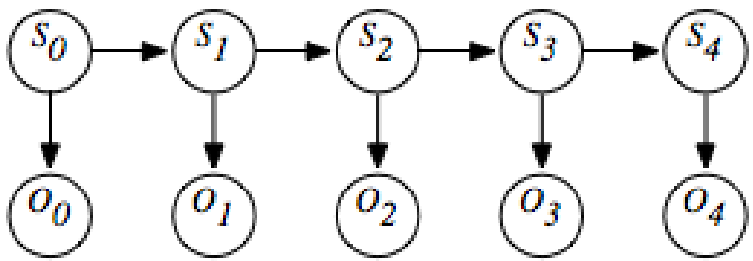
- **Conjunto de Estados**: $s \in \mathcal{S}$
- **Conjunto de Observaciones**: $o \in \mathcal{O}$

Formalmente

- **Conjunto de Estados**: $s \in \mathcal{S}$
- **Conjunto de Observaciones**: $o \in \mathcal{O}$
- **Función de Transición**: $T(s', s) = Pr(s'|s)$
- **Función de Observación**: $Z(o|s) = Pr(o|s)$

Formalmente

- **Conjunto de Estados**: $s \in \mathcal{S}$
- **Conjunto de Observaciones**: $o \in \mathcal{O}$
- **Función de Transición**: $T(s', s) = Pr(s'|s)$
- **Función de Observación**: $Z(o|s) = Pr(o|s)$
- **Modelo Gráfico**:



- **Modelo Probabilistico**:

$$Pr(s_0, s_1, \ldots, s_n, o_1, o_2, \ldots, o_n) = \prod_{i=1}^{n} Pr(s_i|s_{i-1}) Pr(o_i|s_i)$$

Volviendo al Tren

- **Variables de Estado**: $x \in [0, x_{max}], v \in [-v_{max}, v_{max}]$
- **Conjunto de Observaciones**: $r \in \{0, 1, 2, \ldots, x_{max}\}$ (discreto)

Volviendo al Tren

- **Variables de Estado**: $x \in [0, x_{max}], v \in [-v_{max}, v_{max}]$
- **Conjunto de Observaciones**: $r \in \{0, 1, 2, \ldots, x_{max}\}$ (discreto)
- **Función de Transición**:
  $T(x', v', x, v) = \mathcal{N}(x'; x + v \cdot \Delta t, \sigma_{pos}) \times \mathcal{N}(v'; v, \sigma_{vel})$
- **Función de Observación**:

$$Z(r|x, v) = \begin{cases} 0.25 & \text{if } r = round(x) - 1 \\ 0.5 & \text{if } r = round(x) \\ 0.25 & \text{if } r = round(x) + 1 \\ 0 & \text{else} \end{cases}$$

Ejemplos de consultas al modelo

Imagine una secuencia:

1 0 1 1 2 1 2 2 2 1 2 3 3 3 4 5 7 6 6 7

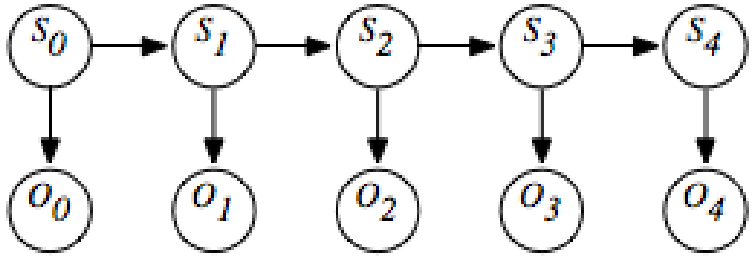
- **a)** ¿Cuál es la probabilidad de que el tren esté entre el kilómetro 15 y 20 al tiempo 40?
- **b)** ¿Cuál es la posición esperada del tren al tiempo 40?
- **c)** ¿Cuál es la velocidad más probable del tren al tiempo 40?

Métodos

- **Inferencia en Variables Ocultas**. ¿Cuál es el valor más probable, el valor esperado, o la distribución de probabilidad de una variable de oculta, dada una secuencia de observaciones?
- **Aprendizaje y Selección de Modelos**. Imagine que tenemos dos modelos ($M_1 = (T_1, Z_1), M_2 = (T_2, Z_2)$). ¿Qué modelo es mejor para una secuencia de observaciones? ¿Cuál es el mejor modelo $M = (T, Z)$ dada una familia de funciones para varias secuencias observadas?
- **Control de Cadenas de Markov Ocultas**. Más conocidos como procesos decisionales de Markov parcialmente observables (POMDPs). En cada tiempo se puede realizar una acción que modifica el estado y se obtiene una recompensa.

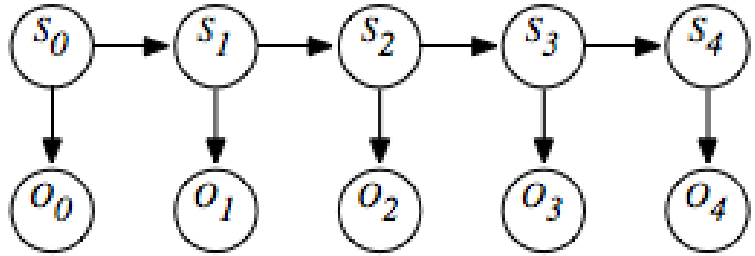
Filtrado (Programación Dinámica)

- **Objetivo**: $Pr(s_t|z_1, z_2, \ldots, z_t) = Pr(s_t|z_{1:t}) = \frac{Pr(s_t, z_{1:t})}{Pr(z_{1:t})}$



Filtrado (Programación Dinámica)

- **Objetivo**: $Pr(s_t|z_1, z_2, \ldots, z_t) = Pr(s_t|z_{1:t}) = \frac{Pr(s_t, z_{1:t})}{Pr(z_{1:t})}$

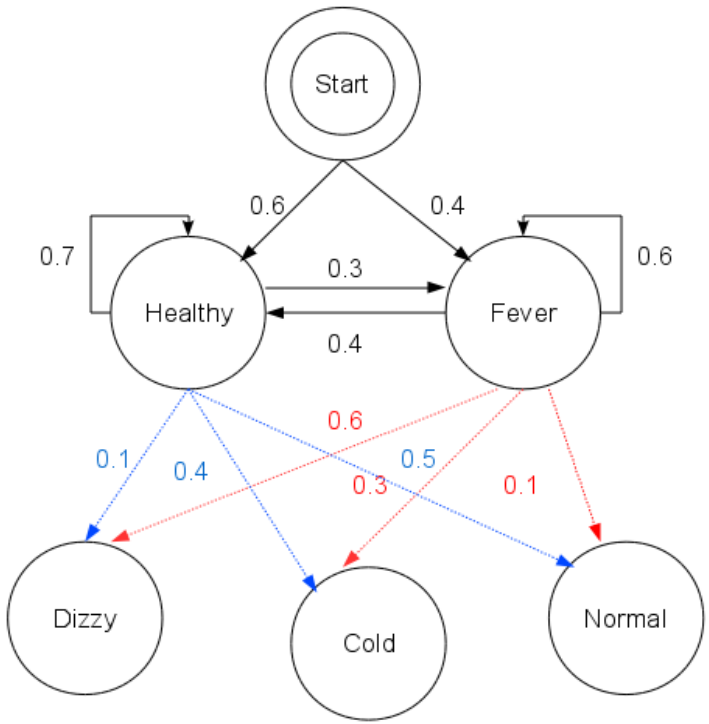


- **Algoritmo Forward**: Calcular $Pr(s_t, z_{1:t})$

$$
\begin{aligned}
Pr(s_t, o_{1:t}) &= \sum_{s_{t-1}} Pr(s_t, o_{1:t}, s_{t-1}) \\
&= \sum_{s_{t-1}} Pr(o_t|s_t, s_{t-1}, o_{1:t-1}) Pr(s_t|s_{t-1}, o_{1:t-1}) Pr(x_{t-1}, o_{1:t-1}) \\
&= \sum_{s_{t-1}} Pr(o_t|s_t) Pr(s_t|s_{t-1}) Pr(x_{t-1}, o_{1:t-1}) \\
\alpha_t(s_t) &= \sum_{s_{t-1}} Z(o_t, s_t) T(s_t, s_{t-1}) \alpha_{t-1}(s_{t-1})
\end{aligned}
$$

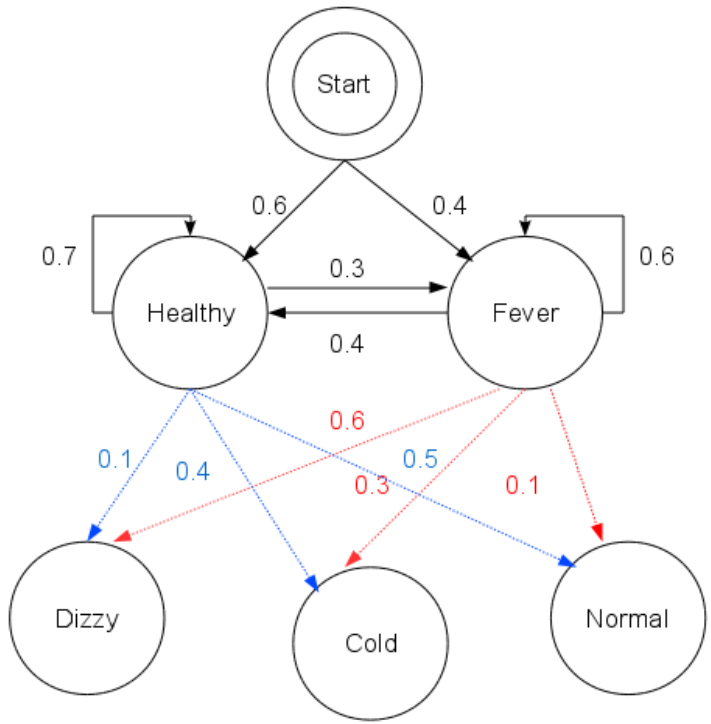
Ejemplo Filtrado

- **Problema**: Un paciente puede estar saludable o con fiebre,
  pero sin un termometro solo podemos observar si esta mareado, con frio o si se siente bien.



Ejemplo Filtrado

- **Problema**: Un paciente puede estar saludable o con fiebre,
  pero sin un termometro solo podemos observar si esta mareado, con frio o si se siente bien.



- **Resolver**: ¿Cuál es el estado del paciente al tiempo t?

$$\mathcal{S} = \{h, f\}, \mathcal{O} = \{d, c, n\}, T = \begin{bmatrix} 0.7 & 0.4 \\ 0.3 & 0.6 \end{bmatrix}, Z = \begin{bmatrix} 0.1 & 0.6 \\ 0.4 & 0.3 \\ 0.5 & 0.1 \end{bmatrix}$$

- **Estado de Creencia** (belief): $\vec{\alpha}_t$, $\vec{\alpha}_0 = [0.6, 0.4]$

Ejemplo Filtrado

- **Resolver**: ¿Cuál es el estado del paciente al tiempo t?

$$\mathcal{S} = \{h, f\}, \mathcal{O} = \{d, c, n\}, T = \begin{bmatrix} 0.7 & 0.4 \\ 0.3 & 0.6 \end{bmatrix}, Z = \begin{bmatrix} 0.1 & 0.6 \\ 0.4 & 0.3 \\ 0.5 & 0.1 \end{bmatrix}$$

- **Belief Inicial**: $\vec{\alpha}_0 = [0.6, 0.4]$
- **Algoritmo Forward**:

$$\alpha_t(s_t) = \sum_{s_{t-1}} Z(o_t, s_t) T(s_t, s_{t-1}) \alpha_{t-1}(s_{t-1})$$

$$\vec{\alpha}_t = diag(Z_{o_t}) T \vec{\alpha}_{t-1}$$

- **Por ejemplo**: $s_t?, t = 3, z_1 = d, z_2 = d, z_3 = n$

Ejemplo Filtrado

$$\mathcal{S} = \{h, f\}, \mathcal{O} = \{d, c, n\}, T = \begin{bmatrix} 0.7 & 0.4 \\ 0.3 & 0.6 \end{bmatrix}, Z = \begin{bmatrix} 0.1 & 0.6 \\ 0.4 & 0.3 \\ 0.5 & 0.1 \end{bmatrix}, \vec{\alpha}_0 = [0.6, 0.4]$$

Por ejemplo: $s_t?, t = 3, o_1 = d, o_2 = d, o_3 = n$

$$\vec{\alpha}_3 = diag(Z_{o_3})T \cdot diag(Z_{o_2})T \cdot diag(Z_{o_1})T \cdot \vec{\alpha}_0$$

Ejemplo Filtrado

$$\mathcal{S} = \{h, f\}, \mathcal{O} = \{d, c, n\}, T = \begin{bmatrix} 0.7 & 0.4 \\ 0.3 & 0.6 \end{bmatrix}, Z = \begin{bmatrix} 0.1 & 0.6 \\ 0.4 & 0.3 \\ 0.5 & 0.1 \end{bmatrix}, \vec{\alpha}_0 = [0.6, 0.4]$$

Por ejemplo: $s_t?, t = 3, o_1 = d, o_2 = d, o_3 = n$

$$\vec{\alpha}_3 = diag(Z_{o_3})T \cdot diag(Z_{o_2})T \cdot diag(Z_{o_1})T \cdot \vec{\alpha}_0$$

$$\begin{aligned}
\vec{\alpha}_3 &= \begin{bmatrix} 0.5 & 0.0 \\ 0.0 & 0.1 \end{bmatrix} \begin{bmatrix} 0.7 & 0.4 \\ 0.3 & 0.6 \end{bmatrix} \begin{bmatrix} 0.1 & 0.0 \\ 0.0 & 0.6 \end{bmatrix} \begin{bmatrix} 0.7 & 0.4 \\ 0.3 & 0.6 \end{bmatrix} \begin{bmatrix} 0.1 & 0.0 \\ 0.0 & 0.6 \end{bmatrix} \begin{bmatrix} 0.7 & 0.4 \\ 0.3 & 0.6 \end{bmatrix} \begin{bmatrix} 0.6 \\ 0.4 \end{bmatrix} \\
&= \begin{bmatrix} 0.35 & 0.2 \\ 0.03 & 0.06 \end{bmatrix} \begin{bmatrix} 0.07 & 0.04 \\ 0.18 & 0.36 \end{bmatrix} \begin{bmatrix} 0.07 & 0.04 \\ 0.18 & 0.36 \end{bmatrix} \begin{bmatrix} 0.6 \\ 0.4 \end{bmatrix} \\
&= \begin{bmatrix} 0.07070 \\ 0.01686 \end{bmatrix}
\end{aligned}$$

Ejemplo Filtrado

$$\mathcal{S} = \{h, f\}, \mathcal{O} = \{d, c, n\}, T = \begin{bmatrix} 0.7 & 0.4 \\ 0.3 & 0.6 \end{bmatrix}, Z = \begin{bmatrix} 0.1 & 0.6 \\ 0.4 & 0.3 \\ 0.5 & 0.1 \end{bmatrix}, \vec{\alpha}_0 = [0.6, 0.4]$$

Por ejemplo: $s_t?, t = 3, o_1 = d, o_2 = d, o_3 = n$

$$\vec{\alpha}_3 = diag(Z_{o_3})T \cdot diag(Z_{o_2})T \cdot diag(Z_{o_1})T \cdot \vec{\alpha}_0$$

$$\begin{aligned}
\vec{\alpha}_3 &= \begin{bmatrix} 0.5 & 0.0 \\ 0.0 & 0.1 \end{bmatrix} \begin{bmatrix} 0.7 & 0.4 \\ 0.3 & 0.6 \end{bmatrix} \begin{bmatrix} 0.1 & 0.0 \\ 0.0 & 0.6 \end{bmatrix} \begin{bmatrix} 0.7 & 0.4 \\ 0.3 & 0.6 \end{bmatrix} \begin{bmatrix} 0.1 & 0.0 \\ 0.0 & 0.6 \end{bmatrix} \begin{bmatrix} 0.7 & 0.4 \\ 0.3 & 0.6 \end{bmatrix} \begin{bmatrix} 0.6 \\ 0.4 \end{bmatrix} \\
&= \begin{bmatrix} 0.35 & 0.2 \\ 0.03 & 0.06 \end{bmatrix} \begin{bmatrix} 0.07 & 0.04 \\ 0.18 & 0.36 \end{bmatrix} \begin{bmatrix} 0.07 & 0.04 \\ 0.18 & 0.36 \end{bmatrix} \begin{bmatrix} 0.6 \\ 0.4 \end{bmatrix} \\
&= \begin{bmatrix} 0.07070 \\ 0.01686 \end{bmatrix}
\end{aligned}$$

$$\begin{aligned}
Pr(s_t|z_{1:t}) &= \frac{Pr(s_t, z_{1:t})}{Pr(z_{1:t})} \\
&= \frac{Pr(s_t, z_{1:t})}{\sum_s Pr(s, z_{1:t})} \\
&= \begin{bmatrix} 0.80745 \\ 0.19255 \end{bmatrix}
\end{aligned}$$

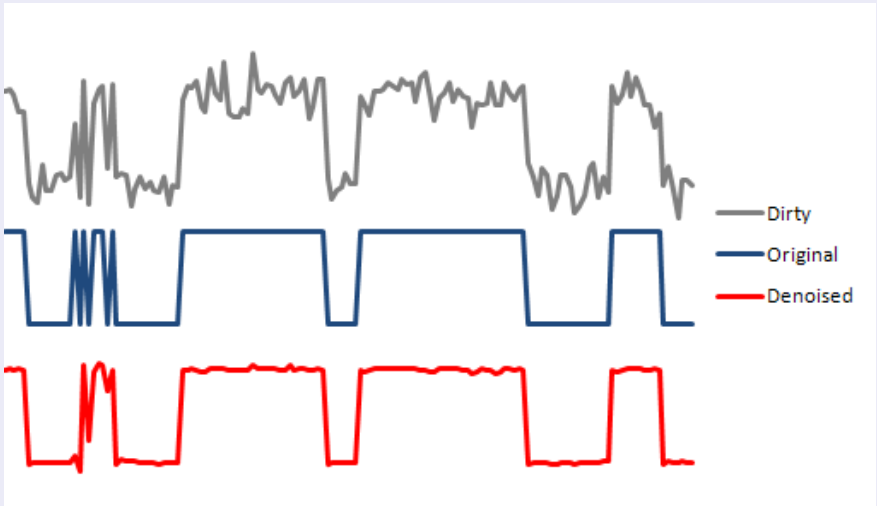
$$Pr(z_{1:t}) = 0.087560$$

En el tintero...

- **Algoritmo Forward-Backward**: para hacer smoothing (estimar en el medio)
  $Pr(s_k|o_{1:t}) \propto Pr(o_{k+1:t}|s_k)Pr(s_k|o_{1:k})$
- **Algoritmo de Viterbi**: para obtener la secuencia más probable de estados
- **Algoritmo de Baum–Welch**: para aprender el modelo de una HMM

Ejemplo Señales

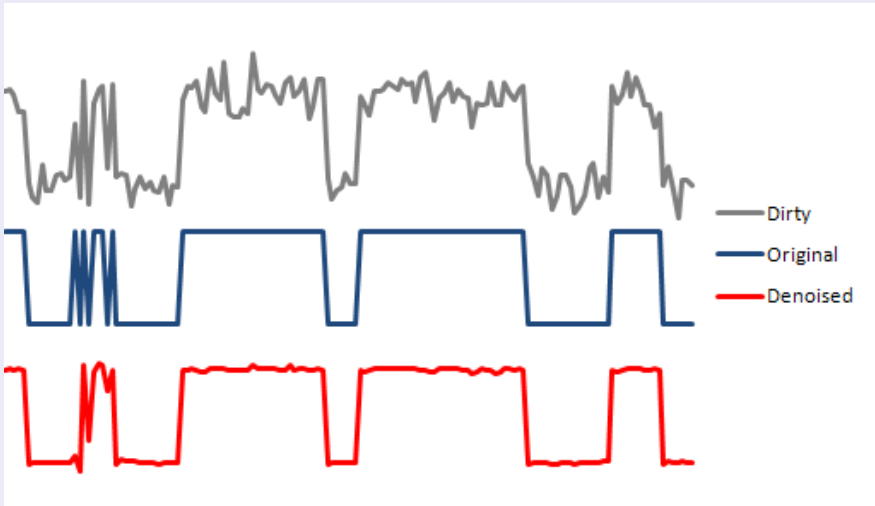
Pulso Oculto



Imagine una señal con SNR moderado. A cada instante t, la señal es una constante c si el evento X está ocurriendo, y cero si no. Considere un error Gaussiano de σ. La probabilidad de que el evento empieze a ocurrir es de 0.3 y de que continue de 0.8.

Ejemplo Señales

Pulso Oculto

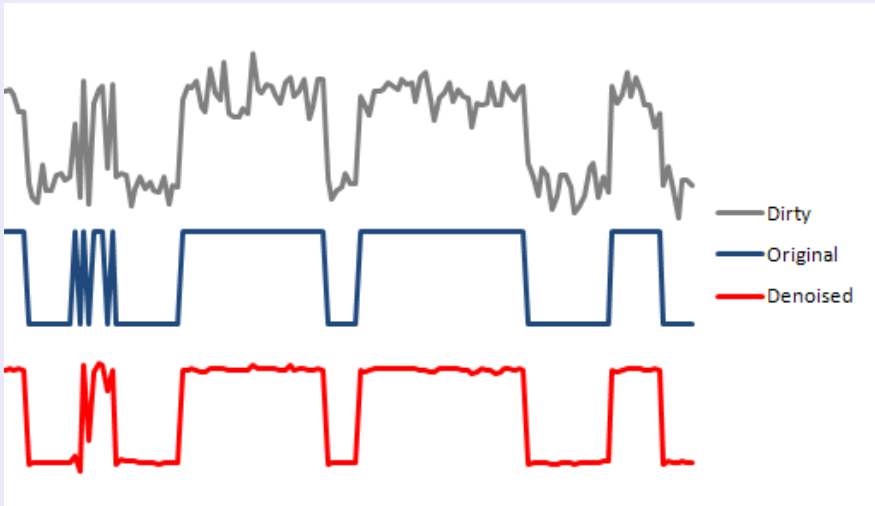


Imagine una señal con SNR moderado. A cada instante t, la señal es una constante c si el evento X está ocurriendo, y cero si no. Considere un error Gaussiano de σ. La probabilidad de que el evento empieze a ocurrir es de 0.3 y de que continue de 0.8.

- $\mathcal{S} = \{0, c\}, \mathcal{O} = \mathbb{R}$
- $T(s', s) = \begin{bmatrix} 0.7 & 0.8 \\ 0.3 & 0.2 \end{bmatrix}$
- $Z(o, s) = \mathcal{N}(s, \sigma)$

Ejemplo Señales

Pulso Oculto



Imagine una señal con SNR moderado. A cada instante t, la señal es una constante c si el evento X está ocurriendo, y cero si no. Considere un error Gaussiano de σ. La probabilidad de que el evento empieze a ocurrir es de 0.3 y de que continue de 0.8.

- $\mathcal{S} = \{0, c\}, \mathcal{O} = \mathbb{R}$
- $T(s', s) = \begin{bmatrix} 0.7 & 0.8 \\ 0.3 & 0.2 \end{bmatrix}$
- $Z(o, s) = \mathcal{N}(s, \sigma)$

- Algoritmo Forward: estimar el señal en el futuro
- Algoritmo de Virerbi: denoising rigido
- Algoritmo Forward-Backward: secuencias en probabilidad
- Algoritmo de Baum–Welch: estimar T y σ

Modelos de Markov Ocultos (HMM)

Mauricio Araya
mauricio.araya@usm.cl

November 4, 2020