Resumen completo del certamen

Agentes Inteligentes · Prof. Mauricio Araya · Razonamiento probabilista, Cadenas de Markov, HMM, MDP/POMDP/RL · Basado en tus PPT, el Certamen Formativo y los talleres

0. Mapa general: cómo se conecta todo

Todo el curso es un solo hilo: **un agente que decide bajo incertidumbre**. Cada tema agrega una pieza.

Modelo	Componentes	¿Veo el estado?	¿Hay acciones y recompensas?	Tema
Red bayesiana	Variables, grafo, CPTs	Parcialmente (evidencia)	No	1
Cadena de Markov	S, T	Sí	No	2
HMM	S, O, T, Z	No (solo observaciones)	No	3
MDP	S, A, T, r, s_0	Sí	Sí	4
POMDP	S, A, Z, T, O, r	No (creencia)	Sí	4
RL	MDP con T desconocida	Sí	Sí	4

Tres ideas que atraviesan todo:
(1) **Independencia condicional**: dado lo relevante, el resto no importa (redes bayesianas → Markov → HMM → MDP).
(2) **Marginalizar** = sumar todas las historias posibles sobre lo que no observo (redes, T^n, Forward, Bellman).
(3) **Aleatoria vs epistémica**: ¿la incertidumbre vive en el mundo o en mi cabeza?

1. Razonamiento probabilista

Redes bayesianas

- Grafo dirigido sin ciclos; cada nodo tiene su CPT dado sus padres. La conjunta se factoriza como producto de CPTs (ej. alarma: 10 parámetros en vez de 31).
- **Inferencia** = Bayes + **marginalización** sobre variables ocultas + independencia condicional.
- **¿Por qué marginalizar?** Bayes necesita P(Evidencia|Hipótesis); si el efecto pasa por un nodo no observado, esa probabilidad no está en ninguna CPT. Se suman todas las rutas (mutuamente excluyentes) sobre el nodo oculto. En continuo, la suma es integral (integración numérica, muestreo, Monte-Carlo).

Las tres estructuras

Estructura	Sin observar el nodo del medio	Observándolo

Cadena X→Y→Z	X influye en Z	X ⊥ Z (bloquea)
Causa común C←A→F	C y F dependientes	C ⊥ F (bloquea)
Efecto común L→A←T	L ⊥ T	L y T dependientes (*explaining away*: abre)

Los dos tipos de incertidumbre

Variabilidad aleatoria	Incertidumbre epistémica
Ruido inherente / variables no modeladas: y = f(x,z) + ε. Más datos no la eliminan, solo estiman mejor sus parámetros. Base de la **inferencia estadística**. Justificación gaussiana: Teorema del Límite Central.	Variable del modelo cuyo valor desconozco: y = f(x,z), x desconocido. Más información la reduce (prior → posterior). Base de la **inferencia bayesiana**.

Errores comunes: evidencia ≠ certeza (que Cristián llame no implica A=1, solo sube mi creencia); borrar una flecha es afirmar independencia; no confundir causa común con efecto común.

2. Cadenas de Markov

- **Propiedad de Markov:** el futuro es independiente del pasado dado el presente. $Pr(X_{t+1}|X_t,...,X_0) = Pr(X_{t+1}|X_t)$.
- Es una **restricción de modelado**, no una verdad: el pasado importa pero se resume en el estado (estadístico suficiente). Si no se cumple (tren con solo posición), se enriquece el estado (se agrega velocidad).
- **Matriz de transición T:** cada distribución condicional suma 1 (en tu PPT, cada columna). Es estacionaria si no cambia con t; una variable como la estación del año la vuelve no estacionaria, y se arregla metiéndola al estado.
- $\mathbf{T^n}$ = transición a n pasos. Multiplicar matrices = marginalizar sobre los estados intermedios.
- **Equilibrio:** T·p = p. Lo que se estabiliza es la **distribución**, no los individuos; el sistema olvida su estado inicial. Es balance de flujos (ej. democratización: 0,2·p = 0,05·(1−p) ⇒ p = 1/5 dictaduras). Un estado con probabilidad de salida pequeña no desaparece salvo que sea absorbente.
- **Aprender T desde una secuencia:** frecuentista (contar y normalizar por columna) vs bayesiano (distribución Beta sobre cada columna con prior α_0; incertidumbre epistémica sobre T). El bayesiano evita probabilidades 0 con pocos datos.
- **Límites:** estados enormes o continuos (maldición de la dimensionalidad) y observabilidad ⇒ HMM.

Errores comunes: T^n es n pasos (el infinito es el equilibrio); en una cadena común el estado se observa, así que la incertidumbre sobre el estado no es epistémica; la incertidumbre aleatoria es el sorteo de la transición, la epistémica es no conocer T.

3. Modelos de Markov Ocultos (HMM)

- En cada instante obtengo una **observación**, no el estado. Modelo: estados S (ocultos), observaciones O, **T(s'|s)** y **Z(o|s)**.

- Conjunta: $\Pi \Pr(s_i|s_{i-1})\cdot\Pr(o_i|s_i)$. Estructura: **cadena** de estados con **causa común** en cada nodo hacia su observación. Dado el estado, las observaciones son independientes; sin él, no.
- **Estado vs observación:** el estado es cómo está el mundo; la observación es lo que el sensor dice de él. T va de estado a estado; Z va de estado a observación. Si Z es perfecta, el estado deja de estar oculto (vuelve a Markov); si Z es igual para todos los estados, la observación no informa.
- **Creencia (belief):** distribución de probabilidad sobre los estados; resume lo observado hasta ahora.

Qué se puede hacer

Tarea	Pregunta	Algoritmo
Filtrado	$\Pr(s_t\|o_{1:t})$: ¿dónde estoy ahora?	Forward (prog. dinámica)
Suavizado	Estimar un instante intermedio usando también observaciones posteriores	Forward-Backward
Secuencia más probable	Trayectoria de estados más probable	Viterbi
Aprendizaje	Mejor T y Z dados los datos	Baum-Welch
Selección de modelos	¿Qué modelo explica mejor la secuencia?	Comparar $\Pr(o_{1:t}\|M)$
Control	Con acciones y recompensas	POMDP

Forward

$$\alpha_t = \text{diag}(Z_{o_t}) \cdot T \cdot \alpha_{t-1} \quad \text{(luego normalizar)}$$

- **Predicción** ($T\cdot\alpha$): marginaliza sobre el estado anterior; la creencia se difumina.
- **Actualización** (diag Z): Bayes con la observación; la creencia se afila.
- La suma de α_t es $\Pr(o_{1:t})$, la verosimilitud de la secuencia.

> **Ejemplo del certamen formativo:** T=[[0,8; 0,3],[0,2; 0,7]], Z(Verde)=[0,6; 0,1], b_0=[0,5; 0,5]. Predicción [0,55; 0,45] → con Verde [0,330; 0,045] → normalizado [0,88; 0,12].

> **Ojo:** el resultado final del paciente en la PPT ([0,0707; 0,01686]) no coincide con mi recálculo ([0,02518; 0,00649] → [0,795; 0,205]). El procedimiento es el mismo; confírmalo con tu profesor. Tampoco confundas Forward (filtrado) con Viterbi (secuencia) ni Baum-Welch (aprendizaje).

4. MDP, POMDP y Aprendizaje por refuerzo

MDP

- MDP = (S, A, T, r, s_0); T(s,a,s') = Pr(s'|s,a); r(s,a,s'). Se asume que el agente **ve el estado**. Un paso: observo s, ejecuto a, recibo r, llego a s'.
- **Una secuencia de acciones no sirve**, porque el resultado es aleatorio: se necesita una **política** condicional π: S→A.
- **Evaluación de una política:** $V^{\pi}(s) = \Sigma_{s'}\, T(s,\pi(s),s')\cdot[r(s,\pi(s),s') + \gamma V^{\pi}(s')]$. En horizonte infinito con descuento γ es un sistema lineal: $V = r + \gamma TV \Rightarrow V = (I-\gamma T)^{-1}r$, resoluble en $O(|S|^3)$.

- **Optimalidad de Bellman:** $V^*(s) = \max_a \Sigma_{s'} T(s,a,s')\cdot[r + \gamma V^*(s')]$. Principio: una política óptima tiene la propiedad de que, sea cual sea el estado inicial y la primera decisión, las decisiones restantes son óptimas para el estado resultante. Métodos: programación dinámica, programación lineal, **value iteration**, **policy iteration**. Funciona bien en juegos de tablero (espacios pequeños).
- **¿Por qué descontar?** Para que la suma infinita converja y para valorar más lo inmediato. **¿Por qué importa la secuencia y no solo la recompensa inmediata?** Una acción con buena recompensa puede llevar a estados peores (Taller 4).

> **Una iteración de value iteration** (como en el certamen anterior): con $V_0=0$, $V_1(s) = \max_a \Sigma_{s'} T(s,a,s')\cdot r(s,a,s')$ (el término γV_0 se anula). Luego se elige la acción que maximiza ese valor.

Incertidumbre en los MDP

Aleatoria	Epistémica
T(s,a,s') es la representación estocástica de dinámica compleja; r puede ser estocástica.	**ADP:** $V^*(s)$ desconocido porque S o A son enormes. **POMDP:** S_t desconocido (estado oculto). **RL:** T desconocida (no se da el modelo).

ADP (Programación dinámica aproximada)

Aproximar $\hat{V}(s;\theta) = \Sigma\, \theta_j\varphi_j(s)$ (combinación lineal de funciones base). Se plantea $\hat{V} \approx r + \gamma T\hat{V}$ y se resuelve por **mínimos cuadrados** en θ. Los parámetros se aprenden con muestras, simulaciones o analíticamente.

POMDP

- POMDP = (S, A, Z, T, O, r); O(s',a,z) = Pr(z|s',a). El estado está **oculto**; el agente solo ve observaciones z.
- **Creencia b:** distribución sobre estados; es **estadístico suficiente** del historial. Se actualiza con Bayes (como el Forward del HMM, pero incorporando la acción).
- **Belief-MDP** (Åström): un POMDP es un MDP cuyo "estado" es la creencia b (continuo). Bellman: $V_t(b) = \max_a [\rho(b,a) + \gamma \int \tau(b,a,b')V_{t-1}(b')db']$, con $\rho(b,a) = \Sigma_s\, b(s)R(s,a)$ (recompensa esperada).
- Sobre la pregunta de *óptimo vs subóptimo con observabilidad parcial*: se compara el valor esperado de las políticas sobre creencias. Un agente reflexivo simple (sin memoria ni creencia) no puede inferir el estado oculto y actuará subóptimamente.

Aprendizaje por refuerzo (RL)

- MDP en que **T es desconocida**. ¿Cómo encontrar π que maximice V? **Dilema exploración vs explotación**: ¿aprender o ganar recompensa? (Ejemplo: ensayos clínicos / bandido.)
- Paradigmas: model-based vs model-free; value iteration vs policy iteration; exploración inteligente vs aleatoria; bayesiano vs "frecuentista".

Model-based	Model-free
Estima $\hat{T}$ (y $\hat{r}$) desde las transiciones observadas y luego planifica con ella (Bellman). Explota con $\hat{\pi} = \text{argmax}\, V_{\hat{T}}$ o explora para mejorar $\hat{T}$.	No estima T ni R. Aprende directamente el valor de las acciones: **Q-learning** (Watkins): $Q_t(s,a) = Q_{t-1}(s,a) + \alpha[r + \gamma \max_{a'} Q(s',a') - Q(s,a)]$ (error de diferencia temporal). Actúa greedy según Q. Problema: convergencia muy lenta.

- **R-MAX** (optimista): si (s,a) se ha visitado menos de m veces, asume Q = $R_{max}/(1-\gamma)$ (recompensa máxima), lo que empuja a explorar; si no, usa $\hat{T}$ = n(s,a,s')/n(s,a). PAC-MDP.
- **RL bayesiano (model-based):** T es una variable aleatoria con creencia b, actualizada con Bayes; política óptima bayesiana argmax V(s,b). **No hay dilema exploración/explotación**: la exploración surge sola de la política óptima. Es intratable ⇒ aproximaciones: BEETLE (poner T en el estado: POMDP; elegante pero lento), BOSS (muestreo optimista; varios parámetros), **BEB** (bonus de exploración $\beta/(1+n_{s,a})$ a la recompensa; simple, un parámetro), **EXPLOIT** (miope: actualiza creencia, toma el modelo esperado $\hat{T}$ = E[T|b], y calcula la política).
- **PAC-MDP / PAC-BAMDP:** con probabilidad alta, el algoritmo es ε-cercano al óptimo salvo en un número polinomial de pasos (BEB fue el primero PAC-BAMDP). El final de la PPT (BOLT, ρ-POMDP, BRL: tesis del profe) es contribución de investigación y es poco probable en el certamen, pero conviene saber que ρ-POMDP permite recompensas basadas en información (entropía) para problemas de recolección de información.

> **Errores comunes:** Model-free *no* construye T ni R (V/F del formativo); en un POMDP la recompensa no tiene que ser positiva; no confundir la creencia (distribución sobre estados) con el estado.

5. Cómo te preguntará el profe

Según el certamen anterior y el formativo, el formato es: **desarrollo** (explicar y comparar con tus palabras), **selección múltiple** (definiciones precisas), **V/F** (propiedades) y **problemas aplicados** (modelar y calcular un caso corto).

Tipo	Ejemplo probable	Cómo responder
Desarrollo	Diferencia entre MDP y POMDP; óptimo vs subóptimo con observabilidad parcial; aleatoria vs epistémica	Definir ambos, decir *qué cambia* en el modelado (creencia) y dar un ejemplo
Desarrollo	¿Por qué marginalizar? ¿Qué es el equilibrio?	Idea + por qué + ejemplo corto
V/F	"Markov: las transiciones dependen de toda la historia" (F). "Agente reflexivo simple en ambiente parcialmente observable" (F). "Model-free almacena T y R" (F). "En el equilibrio la distribución sigue cambiando" (F)	Decir V/F y justificar con la definición
Aplicado	Forward de 1 paso; red bayesiana de 3 nodos; Bellman y 1 iteración de value iteration; modelar un problema como MDP (Taller 4)	Escribir la fórmula, sustituir, interpretar el resultado

> **Qué evalúan los talleres (Taller 4, modelado MDP):** definir S (¿cumple Markov? ¿falta alguna variable?), si el agente **observa** el estado (si no, POMDP con observaciones y Z), A(s), T con probabilidades que suman 1, r (cuidado con recompensas inmediatas que perjudican el largo plazo o incentivan comportamientos no deseados), una política inicial y cuándo conviene explorar vs actuar con lo que se sabe.

6. Mini-glosario

Estado	Cómo está el mundo.	**Observación**	Lo que mide el sensor sobre el estado.
Creencia	Distribución sobre estados.	**Política**	Regla π: estado → acción.
Marginalizar	Sumar sobre todas las historias de lo oculto.	**Descuento γ**	Pondera el valor del futuro.
Bellman	V(s) = valor inmediato + valor futuro esperado.	**Epistémica**	No sé algo del modelo; se reduce con datos.
Aleatoria	Azar inherente; no se elimina.	**Explorar/explotar**	Aprender el modelo vs ganar recompensa.