Tema 1: Razonamiento Probabilista

Agentes Inteligentes · Prof. Mauricio Araya · Resumen según tus PPT (Razonamiento Probabilista, repaso de probabilidades) y el Certamen Formativo

1. Idea central

Un agente casi nunca tiene información perfecta del mundo. El **razonamiento probabilista** es la herramienta para decidir y razonar bajo esa incertidumbre. Las PPT distinguen **dos fuentes de incertidumbre** (sección 3) y usan **Redes Bayesianas** para hacer inferencia (sección 2).

2. Redes Bayesianas e inferencia

Una red bayesiana es un **grafo dirigido sin ciclos** en que cada nodo es una variable aleatoria y cada nodo guarda una tabla de probabilidad condicional (CPT) dado sus padres. Permite escribir una distribución conjunta enorme como producto de tablas pequeñas.

Ejemplo de las PPT (alarma): Ladrón (L) y Temblor (T) → Alarma (A) → Cristián (C) y Francisco (F) llaman por teléfono.

Nodo	Probabilidades
Ladrón	P(L=1) = 0,001
Temblor	P(T=1) = 0,002
Alarma P(A=1 | L,T)	(1,1): 0,95 · (1,0): 0,94 · (0,1): 0,29 · (0,0): 0,001
Cristián P(C=1 | A)	A=1: 0,90 · A=0: 0,05
Francisco P(F=1 | A)	A=1: 0,70 · A=0: 0,01

Pregunta de inferencia: si Cristián y Francisco llamaron (o no), ¿cuál es la probabilidad de que haya un ladrón? Es decir P(L=1 | C=c, F=f).

$$P(L=1 \mid C=c, F=f) = P(C=c, F=f \mid L=1) \cdot P(L=1) \,/\, P(C=c, F=f) \quad \leftarrow \text{Teorema de Bayes}$$

El problema es que P(C,F | L=1) no está en ninguna tabla: la influencia de L sobre C y F pasa por A, que no observamos. Se resuelve **marginalizando** (regla de la suma) sobre la variable oculta:

$$P(C=c, F=f \mid L=1) = P(C,F \mid A=1)\cdot P(A=1 \mid L=1) + P(C,F \mid A=0)\cdot P(A=0 \mid L=1)$$

Y a su vez A depende de T, que tampoco se observa, así que se marginaliza otra vez:

$$P(A=a \mid L=1) = P(A=a \mid L=1, T=1)\cdot P(T=1) + P(A=a \mid L=1, T=0)\cdot P(T=0)$$

> **Receta de inferencia:** (1) Bayes para invertir la pregunta, (2) marginalizar sobre cada variable oculta que está en el camino, (3) usar independencia condicional: C y F dependen solo de A, no de L ni de T.

Número de ejemplo: P(A=1 | L=1) = 0,95·0,002 + 0,94·0,998 = 0,94002. Si hay ladrón, la alarma suena casi seguro, sin importar el temblor.

3. Dos tipos de incertidumbre

Variabilidad aleatoria	Incertidumbre epistémica
Ruido inherente o efecto de variables que no modelamos. $y = f(x,z) + h(x,z,\alpha,\beta,\gamma,\ldots,\omega)$ Se agrupa lo no modelado en un término de error: **$y = f(x,z) + \varepsilon(x,z)$**, con ε con distribución $Pr(E=\varepsilon; \theta)$. "*Modela lo que no modelamos.*" Base de la **inferencia estadística** (inferir desde datos ruidosos). Es la más común.	**Falta de conocimiento** de una variable que sí está en el modelo. $y = f(x,z)$, pero **x es desconocido**. "*Modela el conocimiento de variables.*" Base de la **inferencia bayesiana**. Es menos común que la aleatoria. Se puede reducir con más información.

Para recordar: aleatoria = el mundo es ruidoso aunque lo conozcas todo; epistémica = el mundo es determinista pero yo no sé algo. Esta distinción reaparece en HMM/POMDP (el estado oculto es epistémico) y en MDP (T estocástica es aleatoria).

4. Espacios grandes o continuos

Cuando la variable que se marginaliza es continua, la suma pasa a ser integral:

$$P(A=a) = \int P(A=a \mid B=b)\, P(B=b)\, db$$

Si no se puede resolver analíticamente se usa: **integración numérica**, **muestreo** o **simulación de Monte-Carlo**. Las PPT cierran con la pregunta abierta ¿"mundos abiertos"?, es decir, qué pasa si no sabemos ni qué variables existen.

5. Lo que te preguntaría el certamen (Certamen Formativo)

- **¿Por qué marginalizar?** Porque Bayes necesita P(Evidencia | Hipótesis) y si el efecto pasa por un nodo intermedio no observado, esa probabilidad no está en ninguna CPT. Se suman todas las rutas posibles (mutuamente excluyentes) sobre el nodo oculto.
- **Aleatoria vs epistémica** (ver tabla de arriba, con ejemplos propios).
- **Teorema del Límite Central:** la suma de muchas variables independientes tiende a una Normal; justifica modelar el ruido como gaussiano.
- **Problema tipo (red lineal LI → F → P):** P(LI=1)=0,2; P(F=1|LI=1)=0,9; P(F=1|LI=0)=0,1; P(P=1|F=1)=0,8; P(P=1|F=0)=0,05.
  - P(F=1) = 0,9·0,2 + 0,1·0,8 = **0,26**
  - P(P=1 | LI=1) = 0,8·0,9 + 0,05·0,1 = **0,725** (se marginaliza sobre F porque no se observó)

6. Profundización conceptual

Independencia condicional. Cada variable depende directamente solo de sus padres. Es una restricción de modelado (tú decides las flechas) que permite representar la conjunta con pocas tablas: 10 parámetros en vez de 31 en el ejemplo de la alarma.

Las tres estructuras básicas:

Estructura	Sin observar el nodo del medio	Observando el nodo del medio
Cadena X→Y→Z	X influye en Z vía Y	X y Z independientes
Causa común C←A→F	C y F dependientes	C y F independientes
Efecto común L→A←T	L y T independientes	L y T dependientes (*explaining away*)

> **Explaining away:** si la alarma sonó y además hubo temblor, el temblor ya explica la alarma y el ladrón se vuelve menos probable. Observar un efecto común abre el camino entre sus causas.

Marginalizar = sumar todas las historias posibles compatibles con lo que sé, ponderadas por su probabilidad. Mi ignorancia sobre la variable oculta debe propagarse al resultado. Con variable continua hay infinitas historias, por eso la suma pasa a ser integral.

Aleatoria vs epistémica: ¿la incertidumbre vive en el mundo o en mi cabeza?

- **Aleatoria:** el mundo es ruidoso. Más datos no la eliminan, solo estiman mejor los parámetros θ de ε. Base de la inferencia estadística.
- **Epistémica:** el mundo es determinista pero no sé el valor de una variable. Más información la reduce: prior → (evidencia, Bayes) → posterior. Base de la inferencia bayesiana.
- Reaparece en el curso: T estocástica de un MDP (aleatoria); estado oculto de HMM/POMDP (epistémica, se resume en una creencia); T desconocida en RL (epistémica).

TLC: el error de medición es la suma de muchos efectos pequeños no modelados; esa suma tiende a una Normal aunque cada efecto no lo sea. Por eso se asume ruido gaussiano.

7. Errores comunes y matices

- **Evidencia no es certeza:** que Cristián llame no implica A=1; solo sube mi creencia en A (P(C=1|A=0)=0,05). Esa creencia se propaga hacia atrás y sube un poco la de Ladrón y Temblor.
- **Regla de flujo de información:** en cadena y causa común, observar el nodo del medio **bloquea** el camino; en efecto común, observar el nodo del medio (o su descendiente) lo **abre**. Si el nodo del medio no está observado, la evidencia fluye en ambos sentidos.
- **Explaining away:** dado A=1, L y T compiten por explicarlo; saber T=1 baja la creencia en L.
- **Borrar una flecha** es afirmar independencia: sin A→F, la llamada de Francisco no informa nada sobre la alarma. Puede ser un error de modelado.

- **Markov y el estado:** el pasado sí importa, pero está resumido en el presente (estadístico suficiente). Si no se cumple (p. ej. el tren con solo la posición), se agrega más información al estado (la velocidad).
- **Aleatoria no se elimina** con más datos, solo se estima mejor; **epistémica sí se reduce** (prior → posterior).

8. Resumen en cinco líneas

> 1. Redes bayesianas = grafo + CPTs; factorizan la conjunta.
> 2. Inferencia = Bayes + marginalización sobre variables ocultas + independencia condicional.
> 3. Variabilidad aleatoria: ruido/no modelado (ε); base estadística.
> 4. Incertidumbre epistémica: variable desconocida; base bayesiana.
> 5. Si el espacio es continuo/enorme: integrales, muestreo, Monte-Carlo.