Tema 2: Cadenas de Markov

Agentes Inteligentes · Prof. Mauricio Araya · Resumen según tu PPT "Modelos de Markov Ocultos (HMM)", parte 1, y el Certamen Formativo

1. Qué es un modelo de Markov

- **Modelo:** un conjunto de variables interconectadas.
- **Markov:** "las variables dependen solo de sus vecinos directos".
- **Ventaja:** la restricción simplifica el problema. **Desventaja:** hay que modelar respetando esa restricción.

Es la misma idea de la red bayesiana del Tema 1 (independencia condicional), aplicada a variables que cambian en el tiempo.

2. Procesos estocásticos

- **Proceso:** variables que cambian en el tiempo. **Estado:** el valor de las variables en un instante.
- **Estocástico:** la transición entre estados depende de probabilidades; formalmente, el estado es una variable aleatoria en el tiempo.
- **Problema:** si cada instante depende de todo el pasado, hay demasiadas variables que manejar (ejemplo del "estudiante desconcentrado").

3. La propiedad de Markov

> **"El futuro es independiente del pasado, dado el presente."** Mi estado actual depende solo de mi estado anterior.

$$\Pr(X_{t+1} \mid X_t, X_{t-1}, \ldots, X_0) = \Pr(X_{t+1} \mid X_t)$$

- Es **solo una restricción de modelado**, no una verdad del mundo. Ejemplo "¿dónde está el tren?": con solo la posición, el modelo no es Markov, porque la velocidad también importa. Se arregla enriqueciendo el estado (posición + velocidad).
- El pasado sí importa, pero está **resumido en el estado presente** (estadístico suficiente).
- **Función de transición:** matriz T con los valores Pr(·|·). Cada distribución condicional suma 1.

4. Ejemplo: el estudiante desconcentrado

Estados: c = concentrado, d = desconcentrado. Convención del PPT: **columna = estado actual, fila = estado siguiente**, y cada columna suma 1.

S' | S	c	d
c	0,6	0,2
d	0,4	0,8

suma	1,0	1,0

- $Pr(S_1=c \mid S_0=c) = 0{,}6$ (lectura directa).
- $Pr(S_2=c \mid S_0=c) = 0{,}6 \cdot 0{,}6 + 0{,}2 \cdot 0{,}4 = 0{,}44$. Se suman las dos rutas posibles por el estado intermedio, es decir, **marginalización** como en el Tema 1.
- $Pr(S_6=c \mid S_0=c) = 0{,}33606$. En general, la transición a n pasos es la potencia de la matriz: $\mathbf{T^n}$. Multiplicar matrices equivale a marginalizar sobre todos los caminos intermedios.

5. Equilibrio estadístico

Al dejar $t \to \infty$, todas las columnas de T^t convergen al mismo vector: (1/3, 2/3). El sistema "olvida" de dónde partió.

$$T \cdot p = p \;\Rightarrow\; 0{,}6p + 0{,}2(1-p) = p \;\Rightarrow\; p = 1/3 \text{ (concentrado)}, 1-p = 2/3 \text{ (desconcentrado)}$$

> **Qué significa:** el equilibrio no es que el sistema se detenga; un estudiante individual sigue cambiando. Lo que se estabiliza es la **distribución**: el flujo c→d iguala al flujo d→c.

Ejercicio de las PPT (democratización): dictadura→democracia 20% anual; democracia→dictadura 5%. El sentido común dice "las dictaduras tienden a desaparecer", pero **no es así**: como hay flujo de vuelta, el equilibrio se da en 1/5 dictaduras (balance: $0{,}2 \cdot p = 0{,}05 \cdot (1-p) \Rightarrow p = 1/5$). Una dictadura no es un estado absorbente.

> **Del certamen (V/F):** "En el equilibrio, la distribución sigue cambiando en cada iteración": **Falso**. Se estabiliza y no cambia al aplicar T.

6. Aprendizaje: el problema inverso

Ahora observamos una secuencia de estados y queremos hallar T. Ejemplo del PPT: *c c c c d d c d d d c d d d d d c c c c c c c c c* (24 transiciones).

Conteo	desde c	desde d
→ **c**	11	3
→ **d**	3	7

Frecuentista	Bayesiano
Contar transiciones y normalizar por columna: Pr(c|c)=11/14, Pr(d|c)=3/14, Pr(c|d)=3/10, Pr(d|d)=7/10. Una sola estimación puntual, sin medida de qué tan segura es.	Tratar cada columna de T como una **variable aleatoria** con distribución (Beta) y parámetros iniciales α_0 (prior). $Pr(T \mid \text{lst}, \alpha_0) \propto Pr(\text{lst} \mid T) \cdot Pr(T \mid \alpha_0)$. El prior actúa como conteos virtuales y el resultado es una distribución sobre T. Es incertidumbre **epistémica** sobre T (Tema 1).

7. Para qué sirven

Cualquier aplicación con datos secuenciales: procesamiento de texto (T9, reconocimiento sintáctico), robótica (planificación de rutas), economía (mercados, bolsa), biología (comportamiento celular, ADN), procesamiento de señales (predicción, reducción de ruido) y biomédica (señales cerebrales).

8. Límites de las cadenas de Markov (puente al Tema 3)

- **Conjuntos de estados enormes o continuos:** inferencia más compleja, distribuciones continuas, maldición de la dimensionalidad, funciones de transición enormes pero dispersas. Se atacan con estadística, machine learning, IA y optimización.
- **Observabilidad:** no todo lo modelable es observable. Hay ruido al observar, hay variables ocultas, y la restricción de Markov suele forzar este escenario (el tren). La solución son los métodos bayesianos/gráficos: **HMM** (Tema 3).

9. Resumen en cinco líneas

> 1. Markov: el futuro es independiente del pasado dado el presente; es una restricción de modelado.
> 2. Una cadena se define con estados y una matriz de transición T (cada columna suma 1).
> 3. A n pasos: T^n; multiplicar matrices = marginalizar sobre caminos intermedios.
> 4. Equilibrio: $T \cdot p = p$; lo que se estabiliza es la distribución, no los individuos.
> 5. Aprender T desde una secuencia: contar (frecuentista) o poner una distribución sobre T (bayesiano).