Tema 3: Modelos de Markov Ocultos (HMM)

Agentes Inteligentes · Prof. Mauricio Araya · Resumen según tu PPT "Modelos de Markov Ocultos (HMM)", parte 2, y el Certamen Formativo

1. De la cadena de Markov al HMM

La cadena de Markov del Tema 2 asume que **vemos el estado**. En la realidad:

- Hay **ruido o perturbaciones** al observar una variable.
- Existen **variables ocultas** que sabemos que están.
- La restricción de Markov suele forzar este escenario (el tren: para ser Markov hay que agregar velocidad al estado, y la velocidad no se mide directamente).

> **Principio del HMM:** en cada instante obtengo una **observación**, no un estado. El estado del sistema no está disponible, solo información parcial. Es incertidumbre **epistémica** sobre el estado (Tema 1).

2. El modelo formal

- Estados $s \in S$ (ocultos) y observaciones $o \in O$ (visibles).
- **Función de transición:** $T(s', s) = \Pr(s' \mid s)$. Cómo evoluciona el estado oculto.
- **Función de observación:** $Z(o \mid s) = \Pr(o \mid s)$. Cómo se genera la observación a partir del estado.

$$\Pr(s_0, s_1, ..., s_n, o_1, ..., o_n) = \Pi_{i=1..n} \Pr(s_i \mid s_{i-1}) \cdot \Pr(o_i \mid s_i)$$

Dos supuestos de independencia condicional: (1) el estado actual depende solo del anterior (Markov); (2) la observación depende solo del estado actual. Es una red bayesiana en el tiempo: cadena de estados ocultos con una "hoja" observable colgando de cada uno (**causa común** en cada nodo del Tema 1).

3. Ejemplo: volviendo al tren

- Estado: posición $x \in [0, x_{max}]$ y velocidad $v \in [-v_{max}, v_{max}]$ (continuos).
- Observación: $r \in \{0, 1, ..., x_{max}\}$ (discreta, un sensor por kilómetro).
- Transición: $T(x', v' \mid x, v) = N(x'; x + v \cdot \Delta t, \sigma_{pos}) \cdot N(v'; v, \sigma_{vel})$.
- Observación: $Z(r \mid x, v) = 0{,}5$ si $r = \text{round}(x)$; $0{,}25$ si $r = \text{round}(x) \pm 1$; 0 en otro caso.

Consultas típicas dada una secuencia de lecturas: ¿probabilidad de que el tren esté entre el km 15 y 20 al tiempo 40?; ¿posición esperada?; ¿velocidad más probable?

4. Qué se puede hacer con un HMM (métodos)

Tarea	Pregunta	Algoritmo
Filtrado	¿Dónde estoy ahora? $\Pr(s_t \mid o_{1:t})$	Forward

Suavizado (smoothing)	¿Dónde estaba en un instante intermedio k, sabiendo toda la secuencia? $Pr(s_k \mid o_{1:t}) \propto Pr(o_{k+1:t} \mid s_k) \cdot Pr(s_k \mid o_{1:k})$	Forward-Backward
Secuencia más probable	¿Cuál fue la trayectoria de estados más probable?	Viterbi
Aprendizaje	¿Cuál es el mejor modelo (T, Z) dadas las secuencias?	Baum-Welch
Selección de modelos	Entre $M_1=(T_1,Z_1)$ y $M_2=(T_2,Z_2)$, ¿cuál explica mejor la secuencia observada?	Comparar $Pr(o_{1:t} \mid M)$
Control	Además hay acciones y recompensas	POMDP (Tema 4)

5. Filtrado y algoritmo Forward

Objetivo: $Pr(s_t \mid o_{1:t}) = Pr(s_t, o_{1:t}) / Pr(o_{1:t})$.

El Forward calcula la conjunta no normalizada por **programación dinámica**: marginaliza sobre el estado anterior y reutiliza lo ya calculado.

$$\alpha_t(s_t) = Z(o_t \mid s_t) \cdot \Sigma_{s_{t-1}} T(s_t, s_{t-1}) \cdot \alpha_{t-1}(s_{t-1})$$

En forma matricial: $\boldsymbol{\alpha_t = \mathrm{diag}(Z_{o_t}) \cdot T \cdot \alpha_{t-1}}$. Cada paso tiene dos fases:

- **Predicción:** $T \cdot \alpha_{t-1}$ (la creencia se propaga con la dinámica; es la marginalización del Tema 2; la creencia se "difumina").
- **Actualización:** multiplicar por la verosimilitud de la observación (corrección Bayesiana; la creencia se "afila").

Al final se **normaliza**: $Pr(s_t \mid o_{1:t}) = \alpha_t / \Sigma_s \alpha_t(s)$. La suma de α_t es $Pr(o_{1:t})$, la verosimilitud de la secuencia (sirve para comparar modelos).

> **Por qué una creencia:** como el estado es desconocido, el agente mantiene una distribución de probabilidad sobre los estados. Es un estadístico suficiente del historial de observaciones; esa creencia es lo que el agente "sabe".

6. Ejemplo del PPT: paciente con fiebre

S = {h (saludable), f (fiebre)}, O = {d (mareado), c (con frío), n (se siente bien)}. Sin termómetro solo observamos síntomas.

T (s'|s)	h	f		Z (o|s)	h	f
h	0,7	0,4		**d**	0,1	0,6
f	0,3	0,6		**c**	0,4	0,3

				n	0,5	0,1

Creencia inicial b_0 = [0,6; 0,4]. Observaciones: d, d, n. Aplicando Forward paso a paso:

Paso	Predicción T·α	Con observación	Creencia normalizada
t=1 (d)	[0,58; 0,42]	[0,058; 0,252]	[0,19; 0,81]
t=2 (d)	[0,1414; 0,1686]	[0,01414; 0,10116]	[0,12; 0,88]
t=3 (n)	[0,0504; 0,0649]	[0,02518; 0,00649]	[0,79; 0,21]

Lectura conceptual: dos "mareado" seguidos empujan la creencia hacia fiebre (≈ 88 %); luego "se siente bien" la devuelve hacia saludable (≈ 79 %), pero no del todo, porque la fiebre es persistente (T(f|f)=0,6). Pr($o_{1:3}$) = 0,0317.

> **Ojo, posible error en la diapositiva:** el PPT entrega como resultado final [0,0707; 0,01686] → [0,807; 0,193] y Pr(z)=0,0876. Al recalcularlo con las mismas matrices obtengo [0,02518; 0,00649] → [0,795; 0,205] y 0,0317. El método (diag(Z)·T aplicado en cadena) es el mismo; revisa este número con tu profesor o tus apuntes antes de memorizarlo.

7. Ejemplo del certamen formativo (filtrado de un paso)

Estados {Ok, Falla}; T = [[0,8; 0,3],[0,2; 0,7]] (columna = estado en t−1); Z(Verde) = [0,6; 0,1]; b_0 = [0,5; 0,5]; observación: Verde.

- Predicción: T·b_0 = [0,55; 0,45].
- Actualización: [0,6·0,55; 0,1·0,45] = [0,330; 0,045].
- Normalización: 0,375 ⇒ creencia = [0,88; 0,12]. Pr(Verde) = 0,375.

8. Aplicación: pulso oculto (señales)

Señal con SNR moderado: vale una constante c si el evento X ocurre y 0 si no, más error gaussiano σ. Probabilidad de que el evento empiece: 0,3; de que continúe: 0,8. Estados S = {0, c}, observación continua O = $\mathbb{R}$, Z(o | s) = N(s, σ).

- **Forward:** estimar la señal en el futuro (predicción).
- **Viterbi:** "denoising" rígido (la secuencia única más probable).
- **Forward-Backward:** secuencias en probabilidad (suavizado).
- **Baum-Welch:** estimar T y σ desde los datos.

Nota: en el texto del PPT la matriz T de esta diapositiva aparece como [0,7 0,8; 0,3 0,2], lo que no calza con "continúa con 0,8"; confírmalo en la diapositiva.

9. Del HMM a los POMDP

Si además hay acciones y recompensas, el HMM se convierte en un **POMDP** (Tema 4): el agente decide cómo actuar sin ver el estado, usando la creencia.

10. Resumen en cinco líneas

> 1. HMM = cadena de Markov con estado oculto + observaciones ruidosas: (S, O, T, Z).
> 2. La conjunta se factoriza como $\Pi \Pr(s_i|s_{i-1})\cdot\Pr(o_i|s_i)$.
> 3. Como el estado es epistémico, el agente mantiene una creencia (distribución sobre estados).
> 4. Filtrado = Forward: predecir con T, corregir con Z, normalizar. $\alpha_t = \text{diag}(Z_{o_t})\cdot T\cdot\alpha_{t-1}$.
> 5. Otras tareas: suavizado (Forward-Backward), secuencia más probable (Viterbi), aprendizaje (Baum-Welch), control (POMDP).