Tema 4: MDP, POMDP y Aprendizaje por Refuerzo

Agentes Inteligentes · Prof. Mauricio Araya · Resumen según tu PPT "Markov Decision Processes and Reinforcement Learning", el Certamen Formativo y el Taller 4

1. De la cadena de Markov al MDP

Un MDP es una cadena de Markov a la que se le agregan **acciones** (el agente influye en la transición) y **recompensas** (hay un objetivo). Se define como **(S, A, T, r, s_0)**:

- S: espacio de estados · A: espacio de acciones · s_0: estado inicial.
- T(s,a,s') = Pr(s'|s,a): función de transición estocástica.
- r(s,a,s'): función de recompensa (escalar).

El agente **observa el estado**, ejecuta una acción, el ambiente transiciona y entrega una recompensa. El ciclo se repite (percepciones ← sensores; acciones → actuadores).

2. Políticas: por qué no sirve un plan

Como el resultado de cada acción es aleatorio, **una secuencia fija de acciones es inútil**: no puede reaccionar a lo que realmente ocurrió. Se necesita una **política condicional** π: S → A que diga qué hacer en cada estado.

> **Idea clave:** al fijar una política, el MDP se reduce a una **cadena de Markov con recompensas** (la del Tema 2). Evaluarla es calcular cuánta recompensa acumulada se espera.

3. Evaluación de una política

- **Horizonte finito H:** $V_H = E[\Sigma_{t=0..H}\, r(S_t, \pi_t(S_t), S_{t+1}) \mid s_0]$. Recursión: $V_t(s) = \Sigma_{s'}\, T(s,\pi(s),s')\cdot[r(s,\pi(s),s') + V_{t-1}(s')]$.
- **Horizonte infinito** (T y r estacionarias, con descuento γ): $V^{\pi}(s) = \Sigma_{s'}\, T(s,\pi(s),s')\cdot[r + \gamma V^{\pi}(s')]$. Es un sistema lineal: $V = r + \gamma TV \Rightarrow \mathbf{V = (I - \gamma T)^{-1}\, r}$, resoluble directamente en $O(|S|^3)$.
- **Descuento γ:** hace converger la suma infinita y pondera más lo inmediato que lo lejano. γ cercano a 0 = miope; cercano a 1 = visión de largo plazo.

4. Optimalidad de Bellman

Se busca $\pi^* = \text{argmax}_{\pi}\, E[\Sigma\, \gamma^t\, r(S_t, \pi(S_t), S_{t+1}) \mid s_0]$.

> **Principio de optimalidad (Bellman):** una política óptima tiene la propiedad de que, cualquiera sea el estado inicial y la primera decisión, las decisiones restantes forman una política óptima para el estado resultante.

$$V^*(s) = \max_{a \in A} \Sigma_{s' \in S}\, T(s,a,s') \cdot [\, r(s,a,s') + \gamma\, V^*(s')\,]$$

- Es la ecuación de evaluación pero con un **max** sobre las acciones: elijo la acción que maximiza recompensa inmediata + valor futuro esperado.
- Métodos: programación dinámica, programación lineal, **value iteration** (aplicar repetidamente la ecuación partiendo de V_0=0), **policy iteration** (evaluar y mejorar la política alternadamente).
- Complejidad: P-completo para espacios discretos. Muy exitoso en juegos de tablero (espacios pequeños de estados y acciones).
- Una iteración de value iteration con V_0=0: $V_1(s) = \max_a \Sigma_{s'} T(s,a,s')\cdot r(s,a,s')$.

5. Tres fuentes de incertidumbre en MDP (la clave del tema)

Tipo	Qué es	Extensión
Aleatoria	T es la representación estocástica de dinámica compleja; r puede ser estocástica.	Ya está en el MDP
Epistémica 1	V*(s) desconocido porque S o A son enormes.	**ADP** (programación dinámica aproximada)
Epistémica 2	El estado S_t está oculto.	**POMDP**
Epistémica 3	T es desconocida (no se entrega el modelo).	**Aprendizaje por refuerzo**

6. ADP: evaluación aproximada

Cuando hay demasiados estados, no se guarda V(s) para cada uno. Se aproxima con una función con parámetros θ, por ejemplo una combinación lineal de funciones base: $\hat{V}(s;\theta) = \Sigma_{j=1..k}\, \theta_j\, \varphi_j(s)$. Se exige $\hat{V} \approx r + \gamma T\hat{V}$ y se resuelve por **mínimos cuadrados**: $\operatorname{argmin}_\theta \|(\Phi - \gamma T\Phi)\theta - r\|^2$. Los parámetros pueden aprenderse con muestras, simulaciones o analíticamente. Idea: **generalizar** entre estados parecidos.

7. POMDP: MDP con estado oculto

- POMDP = (S, A, Z, T, O, r). Se agregan observaciones Z y la **función de observación** O(s',a,z) = Pr(z|s',a). El estado está oculto; el agente solo ve z.
- Es un HMM (Tema 3) al que se le suman acciones y recompensas.
- **Creencia b:** distribución de probabilidad sobre los estados; **estadístico suficiente** del historial. Se actualiza con Bayes tras cada acción y observación.
- **Belief-MDP** (Åström): al usar la creencia como "estado", el POMDP se convierte en un MDP continuo sobre el espacio de creencias:

$$V_t(b) = \max_a \left[\, \rho(b,a) + \gamma \int \tau(b,a,b')\, V_{t-1}(b')\, db' \,\right] \quad \text{con} \quad \rho(b,a) = \Sigma_s\, b(s)\, R(s,a)$$

ρ es la recompensa esperada bajo la creencia; τ es cómo cambia la creencia (la transición entre creencias).

> **Respuesta modelo (certamen formativo):** en un MDP clásico el agente conoce el estado y la política mapea S → A. En un POMDP hay incertidumbre epistémica: no conoce el estado, mantiene una creencia, y el problema se transforma en un MDP continuo sobre el espacio de creencias, donde Bellman evalúa la recompensa esperada y las transiciones actualizan la creencia en lugar del estado físico.

- **Recolección de información:** como el valor depende de la creencia, a veces conviene una acción cuyo único mérito es informar (mirar, medir). Problemas de diagnóstico médico, vigilancia o localización son de este tipo. Pero $\rho(b,a) = \Sigma\, b(s)R(s,a)$ *no es una medida de información*; la extensión **ρ-POMDP** permite cualquier función ρ(b), por ejemplo basada en entropía o en distancia a la distribución uniforme.

8. Aprendizaje por refuerzo

Dado un MDP con T **desconocida**, ¿cómo hallar π que maximice V? Dilema: **¿aprender o ganar recompensa?** (exploración vs explotación). Ejemplo: ensayos clínicos (bandido): maximizar pacientes sanos pero el efecto de los medicamentos solo se conoce parcialmente.

Model-based	Model-free
Estima $\hat{T}$ desde las transiciones observadas y planifica sobre ese modelo: explota con $\hat{\pi} = \text{argmax}\, V_{\hat{T}}$ o explora para mejorar $\hat{T}$. Problema: el dilema exploración/explotación.	No estima T ni R. Aprende directamente el valor de las acciones, **Q-learning**: $Q_t(s,a) = Q_{t-1}(s,a) + \alpha[\, r + \gamma \max_{a'} Q_{t-1}(s',a') - Q_{t-1}(s,a)\,]$ (el corchete es el error de diferencia temporal). Actúa greedy según Q. Problema: convergencia muy lenta.

9. Exploración optimista y RL bayesiano

- **Optimismo ante la incertidumbre. R-MAX**: si el par (s,a) se ha visitado menos de m veces, se asume $Q = R_{max}/(1-\gamma)$ (lo mejor posible), lo que empuja a visitarlo; si ya se visitó suficiente, se usa $\hat{T}(s,a,s') = n(s,a,s')/n(s,a)$ y se resuelve el punto fijo. Es PAC-MDP.
- **RL bayesiano (model-based):** T es una variable aleatoria con distribución Pr(T|b); b es la creencia sobre los modelos y se actualiza con Bayes. Política óptima bayesiana: argmax V(s,b). **No existe el dilema**, porque la exploración surge sola de la política óptima: explora solo cuando la información esperada vale la pena.
- Resolverlo exactamente es intratable. **BEETLE**: poner T en el estado y resolver un POMDP (elegante, lento). **BOSS**: muestrea modelos y es optimista (varios parámetros). **BEB**: suma a la recompensa un bono $\beta/(1+n_{s,a})$ que decrece con las visitas (simple, un parámetro). **EXPLOIT**: actualiza la creencia, toma el modelo esperado $\hat{T}=E[T|b]$ y calcula una política (miope, sin bono).
- **PAC-MDP / PAC-BAMDP:** con probabilidad $1-\delta$, el algoritmo es ε-cercano al óptimo salvo en un número polinomial de pasos. BEB fue el primer PAC-BAMDP.

> **Conexión importante:** el RL bayesiano es un POMDP en que el "estado oculto" incluye a T. Por eso se une todo el curso: lo desconocido (estado, modelo) se maneja con una **creencia**

> actualizada por Bayes.

10. Lo que pide el Taller 4 (cómo modelar)

- Definir S (¿cumple Markov? ¿falta alguna variable?), A(s), T con probabilidades que suman 1, r y criterio de desempeño (recompensa acumulada, horizonte H).
- Revisar si el agente **observa** el estado: si no, definir observaciones y la función de observación (POMDP).
- Cuidado con recompensas que incentivan comportamientos no deseados o buenas recompensas inmediatas que perjudican el futuro.
- Proponer una política inicial y decir cuándo conviene explorar y cuándo actuar con el conocimiento disponible.

11. Resumen en cinco líneas

> 1. MDP = cadena de Markov + acciones + recompensas; se resuelve con una política $\pi: S \to A$, no con un plan fijo.
> 2. Bellman: $V^*(s) = \max_a \Sigma\, T \cdot [r + \gamma V^*(s')]$; se obtiene con value/policy iteration.
> 3. Incertidumbre epistémica en MDP: V desconocido (ADP), estado oculto (POMDP), T desconocida (RL).
> 4. POMDP = MDP sobre creencias (belief-MDP); a veces se actúa para informarse.
> 5. RL: model-based vs model-free; dilema exploración/explotación; el enfoque bayesiano lo resuelve de forma óptima pero intratable, y se aproxima (BEB, EXPLOIT).