Agentes Inteligentes

Modelado del agente mediante un MDP

Estudiante: Constanza Flores Vásquez
Profesor: Mauricio Araya
Fecha: 12 de Octubre 2026

---

1. **¿Cuál es el problema de decisión y cómo comienza?**

   El problema de decisión consiste en controlar la colocación de piezas en una partida de Tetris simplificado para sobrevivir hasta colocar 1.000 piezas sin saturar el tablero. En cada turno, el agente decide la rotación y la columna de caída de la pieza activa, buscando despejar líneas y mantener una superficie baja y sin huecos tapados.

   Un paso de tiempo o decisión ocurre de forma discreta al iniciar cada turno, cuando la pieza activa aparece arriba y se conoce también la pieza siguiente en el recuadro 'Next'.

   El estado inicial $s_0 = (M_0, P_0, P_1)$ está formado por el tablero vacío $M_0 = \mathbf{0}_{20\times10}$, la primera pieza en juego P_0 y la siguiente en cola P_1. Este estado varía entre partidas porque el generador aleatorio elige el par inicial (P_0, P_1) de forma estocástica, con una distribución inicial:

   $$P(s_0) = P(M_0 = \mathbf{0}) \cdot P(P_0) \cdot P(P_1) = 1 \cdot \frac{1}{7} \cdot \frac{1}{7} = \frac{1}{49}$$

   asumiendo equiprobabilidad entre las 7 piezas.

   La tarea termina cuando el tablero se llena y una nueva pieza no puede ingresar (fracaso o *Game Over*), o cuando el agente logra colocar las 1.000 piezas con éxito.

2. **¿Cómo definirán el espacio de estados S?**

   El espacio de estados S se define mediante la tupla:

   $$s_t = (M_t, P_t, P_{t+1}) \in S$$

   donde cada variable representa:

   - Matriz del tablero (M_t): Variable discreta binaria $M_t \in \{0,1\}^{20\times10}$, donde 0 indica celda libre y 1 celda ocupada. Representa la superficie y los obstáculos actuales.
   - Pieza activa (P_t): Variable discreta con valores en $\{\mathrm{I}, \mathrm{J}, \mathrm{L}, \mathrm{O}, \mathrm{S}, \mathrm{T}, \mathrm{Z}\}$. Indica la pieza que el agente debe colocar en el turno actual.
   - Pieza siguiente (P_{t+1}): Variable discreta en el mismo conjunto de formas. Indica la pieza visible en cola que entrará en el siguiente turno.

   Ejemplos de estados:

a) Estado típico: $s_1 = (M_{\text{medio}}, \text{T}, \text{I})$, donde el tablero tiene algunas filas inferiores con bloques, la pieza activa es una 'T' y la siguiente en cola es una 'I'.

b) Estado terminal: $s_{\text{terminal}} = (M_{\text{lleno}}, P_t, P_{t+1})$, donde la matriz alcanza la fila superior y bloquea la zona de aparición de una nueva pieza (*Game Over*).

Supuesto de Markov: La formulación cumple con la propiedad $P(s_{t+1} \mid s_t, a_t)$. Al ejecutar la acción a_t, el tablero resultante M_{t+1} se determina completamente a partir de M_t, P_t y a_t. La nueva pieza activa pasa a ser P_{t+1} (ya conocida), y la nueva pieza en espera P_{t+2} se genera de forma aleatoria con probabilidad 1/7, sin depender del historial de turnos pasados. Por tanto, no se requiere información previa para describir la transición.

3. **¿Puede el agente observar el estado definido?**

   El supuesto de observabilidad completa del estado $s_t = (M_t, P_t, P_{t+1})$ es razonable y se cumple estrictamente en este proyecto. En la Tabla 1 se detalla la disponibilidad de cada componente del estado.

Variable del estado	**¿Está disponible para el agente?**	**Sensor, medición o fuente**	**Limitación o ruido**
Matriz del tablero (M_t)	Sí, completamente disponible	Lectura directa en memoria (`board`) del simulador	Ninguna. Lectura determinista y sin errores de medición.
Pieza activa (P_t)	Sí, completamente disponible	Variable de software (`fallingPiece`)	Ninguna. Geometría y posición exactas.
Pieza en cola (P_{t+1})	Sí, completamente disponible	Variable de software (`nextPiece`)	Ninguna. Información íntegra y sin ruido.

Tabla 1: Análisis de observabilidad del espacio de estados definido.

Dado que el estado s_t se definió únicamente con las variables que el entorno expone en cada turno (M_t, P_t, P_{t+1}) y no sobre las piezas futuras ocultas (P_{t+k} con $k \geq 2$), el agente accede por software a la totalidad de s_t sin ruido sensorial ni obstrucciones. En consecuencia, la función de observación es trivial e identidad, $P(z_t = s_t \mid s_t) = 1$, concentrándose la incertidumbre exclusivamente en la transición estocástica hacia s_{t+1}.

4. **¿Cómo definirán el espacio de acciones A?**

   El espacio global de acciones está compuesto por el conjunto de pares discretos de colocación macro:

$$a = (r, c) \in A$$

   donde $r \in \{0, 1, 2, 3\}$ indica la orientación o rotación de la pieza (en múltiplos de 90°), y $c \in \{0, 1, \ldots, 9\}$ corresponde a la columna horizontal donde se ubica el tetraminó antes de descender. La acción aplica la rotación seleccionada, desplaza la pieza a la columna c y ejecuta el *hard drop* hasta impactar con el fondo o los bloques existentes.

   Como las dimensiones del tablero y la forma de cada tetraminó imponen restricciones físicas, el conjunto de jugadas admisibles se expresa en función del estado como $A(s) = A(M_t, P_t) \subseteq A$:

- **Restricciones de orientación y límites:** Solo se permiten las rotaciones válidas según la simetría de la pieza P_t (por ejemplo, el bloque 'O' solo tiene una rotación efectiva $r = 0$, mientras que 'I', 'S' y 'Z' admiten dos). Además, la columna c debe garantizar que el ancho total de la pieza no sobrepase los bordes laterales del tablero ($0 \leq c + \text{ancho}(P_t, r) - 1 \leq 9$).
- **Restricciones de colisión:** Una acción $a \in A(s)$ es válida si y solo si la pieza tiene una trayectoria de caída despejada desde la parte superior del tablero hasta su punto de apoyo, sin intersectar casilleros previamente ocupados ($M_t[y][x] = 1$).
- **Costos asociados:** Las acciones no poseen un costo de ejecución directo en el entorno, pero conllevan un costo de oportunidad implícito en la topografía del tablero, ya que una mala colocación puede elevar la altura de las columnas o crear huecos inaccesibles que comprometan la supervivencia futura.

5. **¿Cómo definirán la función de transición T?**

   La función de transición define la probabilidad condicional de alcanzar el estado $s_{t+1} = (M_{t+1}, P_{t+1}, P_{t+2})$ al ejecutar la acción $a_t = (r, c)$ desde el estado $s_t = (M_t, P_t, P_{t+1})$.

   Esta dinámica se descompone en dos procesos acoplados:

   a) **Evolución determinista del tablero:** La nueva matriz $M_{t+1} = f(M_t, P_t, a_t)$ se obtiene de manera exacta aplicando las reglas del juego (asentamiento de la pieza P_t en la posición indicada y eliminación de filas completadas).

   b) **Generación estocástica de piezas:** La pieza que estaba en cola pasa a ser la activa (P_{t+1}), mientras que la nueva pieza en espera P_{t+2} se extrae del generador aleatorio con probabilidad $P(P_{t+2} = p) = \frac{1}{7}$ para cada pieza p.

   Por lo tanto, la probabilidad de transición condicional es:

$$T(s_t, a_t, s_{t+1}) = \begin{cases} \frac{1}{7}, & \text{si } M_{t+1} = f(M_t, P_t, a_t) \text{ y la nueva pieza activa es } P_{t+1}, \\ 0, & \text{en cualquier otro caso.} \end{cases}$$

   En la Tabla 2 se ilustra la dinámica para dos pares estado–acción representativos bajo esta simplificación:

Estado (s)	**Acción (a)**	**Estado siguiente (s')**	**Probabilidad**	**Fundamento**
$s^{(1)} = (M_1, \mathrm{I}, \mathrm{T})$, pozo en col. 9	$(r = 1, c = 9)$ (vertical)	(M_1', T, p') para $p' \in \mathcal{P}$	$1/7 \approx 0{,}143$ c/u ($\sum = 1{,}0$)	M_1' elimina 4 filas de forma exacta. Entra p' equiprobable.
$s^{(2)} = (M_2, \mathrm{S}, \mathrm{O})$, sup. irregular	$(r = 0, c = 3)$ (horizontal)	(M_2', O, p') para $p' \in \mathcal{P}$	$1/7 \approx 0{,}143$ c/u ($\sum = 1{,}0$)	M_2' fija la pieza generando un hueco. Entra p' uniformemente.

Tabla 2: Tabla local de transiciones para dos pares estado–acción.

Estimación y verificación mediante la plataforma del Taller 2: La componente determinista $f(M_t, P_t, a_t)$ se verifica directamente en el motor lógico (*Headless Engine*), corroborando que las reglas de fijación de bloques y eliminación de líneas se ejecuten de forma exacta. Por su parte, la distribución de transición de piezas (1/7) se puede contrastar experimentalmente ejecutando miles de iteraciones con la función `getNewPiece()` para comprobar que la frecuencia empírica converja a la distribución teórica supuesta.

6. **¿Cómo definirán la recompensa (r) y el criterio de desempeño?**

   La función de recompensa inmediata orienta al agente hacia la supervivencia y estabilidad del tablero:

$$r(s_t, a_t, s_{t+1}) = \begin{cases} -100, & \text{si } s_{t+1} \text{ es fin del juego,} \\ 10L + 1 - 2\Delta\text{Huecos} - 0{,}5\Delta\text{AlturaMax}, & \text{en caso contrario.} \end{cases}$$

   donde L son líneas completadas, ΔHuecos es el cambio neto de huecos y ΔAlturaMax la variación de la columna máxima.

   Valores ilustrativos y comportamiento promovido:

   - **Situación 1 (Limpieza óptima):** Completa 2 líneas, sin huecos y reduce la altura en 1. Recompensa: $10(2) + 1 - 2(0) - 0{,}5(-1) = +21{,}5$. Promueve el vaciado y nivelación de la superficie.
   - **Situación 2 (Colocación riesgosa):** Sin líneas, crea un hueco ($\Delta\text{Huecos} = 1$) y eleva la altura en 2 ($\Delta\text{AlturaMax} = 2$). Recompensa: $10(0) + 1 - 2(1) - 0{,}5(2) = -2{,}0$. Penaliza la creación de obstáculos internos.

   Criterio de desempeño: Se evalúa mediante recompensas descontadas en un horizonte de $H = 1{,}000$ turnos:

$$G_H = \sum_{t=0}^{H-1} \gamma^t r(s_t, a_t, s_{t+1}), \quad \gamma = 0{,}95$$

Se mide por secuencia y no por acción aislada debido a las consecuencias diferidas del juego.

Riesgo de recompensa inmediata y ajuste: Una política miope centrada solo en líneas incentivaría huecos profundos. Para evitarlo, se penaliza el incremento de huecos y se premia la supervivencia (+1), forzando un tablero plano.

7. **¿Qué política inicial propondrán?**

Dado que el estado es completamente observable y el agente modela la estocástica del generador con $P_{t+2} \sim \mathcal{U}(\mathcal{P})$, se propone una política inicial determinista basada en la maximización del valor esperado a dos pasos:

$$\pi(s_t) = \arg \max_{a_t \in A(s_t)} \left[r(s_t, a_t) + \sum_{p \in \mathcal{P}} P(P_{t+2} = p) \cdot \max_{a_{t+1}} V\big(M_{t+2}(M_t, a_t, P_{t+1}, p, a_{t+1})\big) \right]$$

Reglas de decisión operativas:

a) **Filtro de seguridad:** Descartar estrictamente cualquier acción a_t cuyo tablero resultante M_{t+1} conduzca a un estado terminal (*Game Over*).

b) **Evaluación con previsión:** Para cada acción legal a_t, simular el tablero resultante, fijar la pieza en cola P_{t+1} y calcular el promedio ponderado de la mejor puntuación heurística V frente a las 7 piezas posibles para P_{t+2}.

c) **Selección óptima:** Elegir la acción a_t^* que maximice la suma de la recompensa inmediata y el valor futuro esperado.

d) **Regla de desempate:** Si varias acciones presentan el mismo valor esperado, seleccionar aquella que minimice la altura máxima del tablero y reduzca al mínimo los huecos ocultos.

Justificación: Esta política se vincula de forma coherente con las transiciones estocásticas y la función de recompensa, evitando un comportamiento miope y premiando aquellas jugadas que otorgan mayor flexibilidad ante la incertidumbre de las piezas futuras.

Distinción entre obtener información y actuar:

- **Situación para obtener información:** Conviene realizar corridas de prueba en el motor de simulación para verificar empíricamente las frecuencias del generador de piezas y reducir la incertidumbre epistémica (por ejemplo, confirmar si opera con distribución uniforme o un sistema de bolsas tipo *7-Bag*).
- **Situación para actuar con el conocimiento disponible:** Durante una partida activa, el agente debe decidir de inmediato utilizando el modelo probabilístico supuesto (1/7), ya que los tiempos de respuesta por turno exigen una ejecución directa sin detenerse a recalcular o extraer datos externos.